



T.C.
İSTANBUL TOPKAPI
ÜNİVERSİTESİ
MÜHENDİSLİK VE DOĞA
BİLİMLERİ FAKÜLTESİ
YAZILIM MÜHENDİLİĞİ BÖLÜMÜ

CardioGuard-AI

Musa Uluğ
21040301044

BİTİRME PROJESİ

İSTANBUL 2025

Projenin Danışmanı :
Jüri Üyesi :
Jüri Üyesi :

AKADEMİK DÜRÜSTLÜK BEYANI

Mezuniyet projesi olarak sunduğum “**CARDIOGUARD-AI**” başlıklı çalışmanın, bilimsel ahlak ve geleneklere uygun olarak tarafımdan yazıldığını, yararlandığım eserlerin tamamının kaynaklarda gösterildiğini ve çalışmam içerisinde kullanıldıkları her yerde atıf yapıldığını belirtir ve onurumla doğrularım.

Tarih

Öğrenci Adı Soyadı

TEŞEKKÜR

Çalışmalarım süresince bilimsel katkıları ile beni aydınlatan, farklı bakış açıları ile yol gösteren, yakın ilgi ve yardımları ile beni motive eden ve bu günlere gelmemde en büyük katkı sahibi olan sayın’e teşekkürü bir borç bilirim.

Deneysel çalışmalarım sırasında karşılaştığım zorlukları aşmamda yardımlarından dolayı’a ve’e teşekkür ederim.

Ayrıca, çalışmalarım süresince sabır göstererek beni daima destekleyen değerli aileme ve arkadaşlarıma en içten teşekkürlerimi sunarım.

Tarih

Öğrenci Adı

ÖZET

Bu çalışma, 12 derivasyonlu elektrokardiyografi (EKG) sinyalleri üzerinden Miyokard Enfarktüsü (MI) tespiti ve anatomik lokalizasyonunun, klinik karar destek bakış açısıyla güvenilir ve üretime taşınabilir bir sistem tasarımı kapsamında ele alınmasını amaçlamaktadır. Çalışmada problem; manuel EKG yorumlamasının zaman alıcı, subjektif ve hataya açık olması, ayrıca MI lokalizasyonunun doğru belirlenmesinin tedavi planı açısından kritik önem taşıması olarak tanımlanmıştır. Bu doğrultuda CardioGuard-AI için gereksinim analizi gerçekleştirilmiş; fonksiyonel gereksinimlerin yanında güvenilirlik, güvenlik ve performans gereksinimleri ölçülebilir hedeflerle tanımlanmıştır.

Yöntem olarak, veri hazırlama ve modelleme sürecinin sonraki dönemde uygulanmasına zemin oluşturacak şekilde modüler bir mimari kurgulanmış; sistemin işleyişi UML Use Case ve Class diyagramları ile modellenmiş, veri bütünlüğü ve izlenebilirlik gereksinimleri ERD (Varlık-İlişki Diyagramı) üzerinden tasarlanmıştır. Ayrıca sistemin çalışma zamanı akışının ve üretim ortamına taşınabilirliğinin netleştirilmesi amacıyla sıralı akış (sequence) ve dağıtım (deployment) perspektifleri ele alınmış; iş paketleri ve zamanlama planı ile proje yönetimi çıktıları yapılandırılmıştır. Böylece, model çıktılarının standart bir API sözleşmesi üzerinden raporlanması ve olası hataların erken aşamada yakalanmasını hedefleyen fail-fast yaklaşımı gibi güvenilirlik mekanizmaları tasarım seviyesinde konumlandırılmıştır.

Sonuç olarak bu çalışma; CardioGuard-AI projesinin yalnızca kavramsal düzeyde kalmaması için, doğrulanabilir gereksinimler, diyagramlar, veri modeli ve planlama artefaktlarından oluşan kapsamlı bir mühendislik dokümantasyonu sunmakta; bir sonraki dönemde gerçekleştirilecek implementasyon ve doğrulama çalışmalarına doğrudan rehberlik edecek uygulanabilir bir temel oluşturmaktadır.

Anahtar Kelimeler: Elektrokardiyografi, Miyokard Enfarktüsü, Lokalizasyon, Klinik Karar Destek, Sistem Tasarımı, UML, ERD

ABSTRACT

This study aims to address myocardial infarction (MI) detection and anatomical localization from 12-lead electrocardiography (ECG) signals within the scope of a reliable and deployment-ready clinical decision support system design. The problem is defined as the time-consuming, subjective, and error-prone nature of manual ECG interpretation, along with the clinical importance of accurately localizing MI for treatment planning. Accordingly, a requirements analysis for CardioGuard-AI is conducted, and measurable targets are defined not only for functional requirements but also for reliability, security, and performance.

Methodologically, a modular system architecture is proposed to serve as a practical foundation for implementation in the next phase. The system behavior is modeled using UML Use Case and Class diagrams, while data integrity and traceability requirements are designed through an Entity-Relationship Diagram (ERD). In addition, runtime behavior and deployment considerations are clarified by incorporating sequence and deployment perspectives, and project management outputs are structured via work packages and a scheduling plan. Reliability mechanisms—such as a standardized API contract for model outputs and a fail-fast approach to prevent silent failures—are positioned at the design level to improve operational trustworthiness.

As a result, this study provides comprehensive engineering documentation consisting of verifiable requirements, diagrams, a data model, and planning artifacts, ensuring that the CardioGuard-AI project does not remain at a conceptual level. The delivered outputs establish an actionable baseline that directly guides subsequent implementation and validation efforts.

Keywords: Electrocardiography, Myocardial Infarction, Localization, Clinical Decision Support, System Design, UML, ERD

İÇİNDEKİLER

AKADEMİK DÜRÜSTLÜK BEYANI	i
TEŞEKKÜR	ii
ÖZET	iii
ABSTRACT	iv
İÇİNDEKİLER	v
ŞEKİLLER DİZİNİ	vii
ÇİZELGELER DİZİNİ	viii
KISALTMALAR.....	ix
1 GİRİŞ	1
1.1 Problem Tanımı.....	2
1.2 projenin amacı ve kapsamı.....	4
1.3 Projenin katkıları.....	6
2 KAYNAK ARAŞTIRMASI	8
2.2 EKG Sinyali Sınıflandırmasında Derin Öğrenme Yaklaşımları	9
2.3 Miyokard Enfarktüsü Tespiti ve Anatomik Lokalizasyon	11
2.4 PTB-XL Veri Seti: Standartlaşma ve Benchmark Rolü.....	13
2.5 Hibrit Mimari Yaklaşımlar: CNN ve XGBoost Entegrasyonu	15
2.6 Açıklanabilir Yapay Zeka (XAI) ve Klinik Karar Destek Sistemleri	17
2.7 Üretim Sistemlerinde Model İzleme ve Güvenilirlik	18
2.8 Bu Projenin Literatürdeki Konumlandırması.....	20
3 MATERYAL VE YÖNTEM.....	21
3.1 Veri Seti: PTB-XL	22
3.1.1 VERİ SETİNİN ÖZELLİKLERİ.....	22
3.1.2 Veri Bölünmesi (Split Stratejisi)	22
3.1.3 Etiket Dönüşümleri ve Türetilmiş Etiket Sistemi.....	24
3.1.4 Veri ön işleme.....	25
3.2 MODEL MİMARİSİ.....	Hata! Yer işareti tanımlanmamış.
3.2.1 ECGBackbone (CNN Temel Mimarisi)	25
3.2.2 Üç Model Yaklaşımı.....	27
3.3 Hibrit Mimari: CNN + XGBoost Ensemble.....	28
3.3.1 Hibrit Pipeline Mantiğı.....	28
3.3.2 XGBoost Hiperparametreleri.....	29
3.3.3 Feature Schema Lock (Güvenlik).....	29
3.4 İnfersan Orkestrasyonu	30
3.4.1 Üç Aşamalı Karar Akışı	30
3.5 Üretim Güvenilirliği Mekanizmaları.....	31

3.5.1	Fail-Fast Checkpoint Validation.....	31
3.5.2	Mapping Fingerprint Doğrulaması	32
3.5.3	Feature Schema Lock	32
3.6	API Sözleşmesi: AIResult v1.0.....	32
3.6.1	Endpoint Tasarımı	32
3.6.2	Response Contract.....	33
3.6.3	Değerlendirme Metrikleri (Planlanan).....	33
4	SONUÇLAR.....	34
5	TARTIŞMA.....	72
6	İş paketleri ve zamanlama planı.....	75
7	KAYNAKLAR.....	86

ŞEKİLLER DİZİNİ

Şekil 1. Veri seti filtreleme ve etiket kaynağı (data provenance): PTB-XL ham veriden MI seçimi ve lokalizasyon için geçerli alt kümenin oluşturulması.....	23
Şekil 2. MI lokalizasyon etiket haritalama süreci ve mapping fingerprint: SCP kodlarından hedef lokalizasyon sınıf gruplarına dönüşüm.....	25
Şekil 3. ECGBackbone CNN mimarisi (katman analizi): Conv1D tabanlı bloklar ile gömlem (embedding) üretimi.....	26
Şekil 4. İnfersan orkestrasyonu ve tutarlılık kapısı (Consistency Gate): Superclass CNN ve Binary Guard çıktıları üzerinden karar/triage akışı ve lokalizasyon modeline geçiş.....	28
Şekil 5. Hibrit çıkarım hattı ve özellik şeması kilidi (Schema Lock): CNN embedding → ölçekleme → XGBoost bankası → ensemble birleşimi.....	29
Şekil 6. Açıklanabilirlik (XAI) üretim iş akışı: Grad-CAM ve SHAP çıktılarının artefact deposuna kaydı ve AIResult ile ilişkilendirilmesi.....	30
Şekil 7. İstek yaşam döngüsü ve fail-fast kontrol sıralaması: Doğrulama, giriş ayrıştırma, schema lock ve fingerprint kontrolleri ile hata yönetimi.....	31
Şekil 8. Çok katmanlı sistem mimarisi: İstemci-API Gateway-FastAPI model servisi ve AIResult v1.0 çıktı sözleşmesi.....	32
Şekil 9 Gereksinim Bağımlılıkları.....	38
Şekil 10. Kullanım Senaryoları Diyagramı.....	41
Şekil 11. Paket Bağımlılıkları.....	43
Şekil 12. Model Paketi Class Diyagramı.....	46
Şekil 13. Veri Paketi Class Diyagramı.....	49
Şekil 14. Pipeline Paketi Class Diyagramı.....	50
Şekil 15. XAI Paketi Class Diyagramı.....	52
Şekil 16. Backend Paketi Class Diyagramı.....	55
Şekil 17. Planlanan Sınıfların Diyagramı.....	58
Şekil 18. Varlık - İlişki Diyagramı.....	62
Şekil 19. Dağıtım Diyagramı.....	65
Şekil 20. Ana Tahmin Akışı – Klinisyenden başlayarak API, CNN, XGBoost, Guard, Lokalizasyon ve XAI bileşenleri arasındaki etkileşim. 16 adımlık sıralı akış gösterilmektedir.....	67
Şekil 21. Sistem Başlatma Akışı – Main, Doğrulayıcı, Loader ve State bileşenleri arasındaki fail-fast mekanizması. Loop yapısı her model için tekrar eden kontrolleri gösterir.....	68
Şekil 22. Tutarlılık Kontrolü Akışı – API ve Guard bileşenleri arasında alt (alternative) yapısı ile üç farklı senaryo gösterilmektedir. XGBoost Hibrit Pipeline Akışı	69
Şekil 23. XGBoost Hibrit Pipeline Akışı – API, Backbone, Scaler, XGB ve Calib bileşenleri arasındaki etkileşim. Loop yapısı her sınıf için tekrar eden tahmin sürecini gösterir.....	70
Şekil 24. Planlanan Akışlar (v2.0) – RAG entegrasyonu ile klinik kılavuz kullanımı ve LLM rapor üretimi.....	71
Şekil 25. Monte Carlo Dropout ile belirsizlik tahmini akışı.....	71
Şekil 26. UX Şema 1 (EKG Yükleme).....	79
Şekil 27. UX Şema 2 (Sonuçlar).....	81
Şekil 28. UX Şema 3 (XAI Görüntüleme/Raporlama).....	81
Şekil 29. Gantt Şeması.....	84

ÇİZELGELER DİZİNİ

Tablo 1. PTB-XL veri seti dağılımı (Train/Val/Test).....	23
Tablo 2 Veri Yükleme ve İşlem Gereksinimleri.....	34
Tablo 3 Sınıflandırma ve Tahmin Gereksinimleri.....	35
Tablo 4 Hibrit Model Pipeline Gereksinimleri.....	36
Tablo 5 Açıklanabilirlik (XAI) Gereksinimleri.....	36
Tablo 6 API Servisi Gereksinimleri.....	37
Tablo 7 Güvenilirlik ve Güvenlik Gereksinimleri.....	37
Tablo 8 Performans Gereksinimleri.....	38
Tablo 9 Kullanılan XAI Yöntemleri.....	53
Tablo 10 Faz 1 Tamamlanan İş Paketleri ve Çıktıları (WP1.0–WP1.7).....	77
Tablo 11 Faz 2 İş Paketleri ve Çıktıları (WP2.1–WP2.7).....	78
Tablo 12 Faz 3 İş Paketleri ve Çıktıları (WP3.1–WP3.8).....	80
Tablo 13 Faz 4 Deployment ve Operasyon.....	82
Tablo 14 Planlama.....	83
Tablo 15 Gantt Tablosu.....	85

KISALTMALAR

CNN	: Convolutional Neural Network
MI	: Myocardial Infarction (Miyokard Enfarktüsü)
XAI	: Explainable Artificial Intelligence (Açıklanabilir Yapay Zeka)
PTB-XL	: PTB-XL Electrocardiography Database (PTB-XL EKG veri seti)
STTC	: ST/T Change (ST/T değişikliği)
CD	: Conduction Disorder (İletim bozukluğu)
HYP	: Hypertrophy (Hipertrofi)
NORM	: Normal
AMI	: Anterior Myocardial Infarction (Ön MI)
ASMI	: Anteroseptal Myocardial Infarction (Anteroseptal MI)
ALMI	: Anterolateral Myocardial Infarction (Anterolateral MI)
IMI	: Inferior Myocardial Infarction (İnferior MI)
LMI	: Lateral Myocardial Infarction (Lateral MI)

1 GİRİŞ

Kardiyovasküler hastalıklar (KVH), dünya genelinde her yıl yaklaşık 17,9 milyon insanın ölümüne neden olarak, küresel ölüm nedenlerinin başında yer almaktadır. Bu hastalık grubunun en kritik ve acil müdahale gerektiren formlarından biri olan Miyokard Enfarktüsü (MI), kalp kasının yetersiz kan akışı nedeniyle nekroza uğraması olarak tanımlanır ve erken teşhis edilmediğinde kalıcı doku hasarına veya ölüme yol açabilmektedir. Elektrokardiyografi (EKG), MI tespitinde noninvazif, düşük maliyetli ve yaygın olarak kullanılan birincil tanı aracıdır. Ancak, 12-derivasyonlu EKG sinyallerinin manuel yorumlanması, deneyimli kardiyologlar için bile zaman alıcı, subjektif ve hata eğilimli bir süreçtir. Özellikle çoklu damar tutulumu olan hastalarda, MI'nın anatomik lokalizasyonunun doğru belirlenmesi, tedavi planlaması açısından kritik önem taşımakta, ancak mevcut klinik uygulamalarda bu doğruluk oranları istenilen düzeyde bulunmamaktadır.

Son yıllarda yapay zeka ve derin öğrenme teknolojilerinin tıbbi görüntüleme ve sinyal işleme alanlarındaki başarıları, EKG tabanlı otomatik tanı sistemlerine olan ilgiyi önemli ölçüde artırmıştır. Evrişimsel sinir ağları (Convolutional Neural Networks - CNN), ham EKG dalga formlarından otomatik öznitelik çıkarımı yaparak, geleneksel makine öğrenmesi yöntemlerinin gerektirdiği manuel öznitelik mühendisliğini ortadan kaldırmış ve çeşitli kardiyak patolojilerin sınıflandırılmasında yüksek doğruluk oranlarına ulaşmıştır. Bununla birlikte, tek bir derin öğrenme modelinin klinik ortamda güvenilir bir şekilde kullanılabilmesi için, yalnızca yüksek doğruluk oranı yeterli değildir; modelin kararlarının açıklanabilir olması, farklı veri dağılımlarına karşı dayanıklılığı ve üretim ortamındaki hata modlarına karşı güvenli fail-fast mekanizmalarıyla donatılmış olması gerekmektedir.

Bu çalışma, EKG tabanlı MI tespiti ve lokalizasyonu için çoklu model orkestrasyonu, tutarlılık doğrulama mekanizmaları ve açıklanabilir yapay zeka bileşenlerini entegre eden hibrit bir karar destek sistemi geliştirmeyi amaçlamaktadır. Geliştirilen CardioGuard-AI sistemi, yalnızca yüksek performanslı bir sınıflandırıcı olmakla kalmayıp, aynı zamanda klinik güvenilirlik, şeffaflık ve üretim ortamındaki operasyonel dayanıklılık gereksinimlerini de karşılayacak şekilde tasarlanmıştır.

1.1 PROBLEM TANIMI

Miyokard enfarktüsünün erken ve doğru tespiti, hasta mortalitesini azaltma ve kalıcı kalp hasarını önleme açısından yaşamsal önem taşımaktadır. Klinik pratikte, EKG sinyalleri üzerinden yapılan görsel değerlendirme, Q dalgası anormallikleri, ST segment elevasyonu ve T dalgası inversiyonu gibi karakteristik özelliklere dayanmaktadır. Ancak, bu özelliklerin yorumlanması, kardiyologların deneyimine, yorgunluk durumuna ve subjektif değerlendirme kriterlerine bağlı olarak değişkenlik gösterebilmektedir. Bir çalışmada, deneyimli kardiyologların görsel EKG değerlendirmesinde, özellikle left circumflex (LCX) bölgesinde %15 gibi düşük bir duyarlılık, çoklu damar tutulumunda (double vessel, DVT) %24 ve üç damar tutulumunda (triple vessel, TVT) %4 gibi kabul edilemez düzeyde düşük doğruluk oranları saptanmıştır [1]. Bu bulgular, manuel değerlendirmenin güvenilirlik sorunlarını açıkça ortaya koymaktadır.

Yapay zeka tabanlı otomatik EKG analiz sistemlerinin geliştirilmesi, bu sınırlamaları aşmak için umut verici bir yaklaşım sunmaktadır. Ancak, literatürdeki çoğu çalışma, tek bir derin öğrenme modelinin performansına odaklanmakta ve modelin klinik ortamda karşılaşabileceği kritik güvenilirlik sorunlarını yeterince ele almamaktadır. Örneğin, tek bir CNN modelinin yüksek doğruluk oranı sergilemesi, modelin her EKG kaydında aynı güvenilirlikle çalıştığı anlamına gelmemektedir. Özellikle sınır durumlarında (borderline cases), modelin güven düzeyinin düşük olması veya farklı patolojiler arasında kararsız kalması, klinik karar sürecinde yanlış yönlendirmelere neden olabilmektedir. Ayrıca, derin öğrenme modellerinin "kara kutu" doğası, klinisyenlerin modelin kararlarına güvenmesini zorlaştırmakta ve modelin hangi EKG özelliklerine dayanarak karar verdiğinin anlaşılamaması, klinik kabul edilebilirliği olumsuz etkilemektedir.

Üretim ortamında karşılaşılan bir diğer kritik sorun ise "sessiz hata" (silent failure) riskidir. Özellikle, CNN tabanlı öznitelik çıkarımının ardından XGBoost gibi gradient boosting algoritmaları kullanılarak sınıflandırma yapılan hibrit sistemlerde, CNN modelinin mimarisinde yapılan değişiklikler (örneğin, çıktı boyutunun 64'ten 128'e çıkması) veya özniteliklerin sırasının değişmesi, XGBoost modelinin beklenmedik ve mantıksız tahminler üretmesine neden olabilmektedir. Bu tür hatalar, sistem tarafından hata mesajı üretmeden sessizce gerçekleştiğinden, yalnızca sonuçların klinik olarak anlamsız olması durumunda fark edilebilmektedir [2]. "Bu durum, hasta güvenliği açısından ciddi bir risk oluşturmaktadır.

MI lokalizasyonu görevinde ise, PTB-XL gibi geniş ölçekli veri setlerindeki etiket karmaşıklığı ve çeşitliliği, ek zorluklar yaratmaktadır. PTB-XL veri setinde, MI ile ilişkili 13'ten fazla SCP (Standardized Communication Protocol for Computer Assisted Electrocardiography) kodu bulunmakta ve bu kodların bir kısmı tek bir anatomik bölgeye karşılık gelirken, bazıları (örneğin, ILMI - inferolateral MI) birden fazla bölgeyi temsil etmektedir [3]. Ayrıca, posterior MI (PMI) gibi nadir görülen lokalizasyon tiplerinin veri setindeki düşük temsili, modelin bu tür durumları öğrenmesini zorlaştırmaktadır. Etiket uzayındaki bu türetme (derived labeling) sürecinin dokümanate edilmemesi veya modelin eğitildiği etiket uzayının üretim ortamında kullanılan etiket uzayından farklılaşması (label space drift), modelin ürettiği sonuçların klinik olarak geçersiz hale gelmesine neden olabilmektedir.

Bu çalışmanın ele aldığı temel problem, EKG tabanlı MI tespiti ve lokalizasyonu için, yalnızca yüksek doğruluk oranına sahip olmakla kalmayıp, aynı zamanda klinik güvenilirlik, açıklanabilirlik ve üretim ortamında operasyonel güvenlik gereksinimlerini de karşılayan entegre bir karar destek sisteminin eksikliğidir. Mevcut yaklaşımların tek model odaklı doğası, çoklu doğrulama mekanizmalarının eksikliği, açıklanabilirlik bileşenlerinin sistem tasarımına sonradan eklenmiş eklentiler olarak kalması ve üretim ortamındaki hata modlarına karşı yetersiz koruma mekanizmaları, bu çalışmanın motivasyonunu oluşturmaktadır.

1.2 PROJENİN AMACI VE KAPSAMI

Bu çalışmanın temel amacı, 12-derivasyonlu EKG sinyallerinden miyokard enfarktüsü ve diğer kardiyak patolojilerin tespiti için, çoklu model orkestrasyonu, tutarlılık doğrulama mekanizmaları ve açıklanabilir yapay zeka bileşenlerini entegre eden hibrit bir karar destek sistemi geliştirmektir. Sistem, tek bir modelin kararına bağımlı kalmayarak, farklı görevler için özelleştirilmiş üç ayrı CNN modelinin çıktılarını entegre etmekte ve bu modeller arasındaki uyumsuzlukları tespit ederek klinisyenlere ek uyarılar sunmaktadır.

Sistemin birincil amaçları şu şekilde sıralanabilir: İlk olarak, EKG sinyallerinden dört ana kardiyak patoloji sınıfının (MI - Miyokard Enfarktüsü, STTC - ST/T Değişiklikleri, CD - İletim Bozuklukları, HYP - Hipertrofi) çoklu-etiketli sınıflandırmasının yapılması hedeflenmektedir. Bu sınıflandırma görevi için, PTB-XL veri setinin hiyerarşik etiket yapısından yararlanılarak eğitilmiş bir superclass CNN modeli kullanılmaktadır. İkinci olarak, MI tespitinde güvenilirliği artırmak amacıyla, superclass CNN modelinin MI tahmini, ikinci bir bağımsız binary MI CNN modeli tarafından doğrulanmaktadır. Bu iki modelin çıktıları, bir tutarlılık kontrol mekanizması (consistency guard) tarafından karşılaştırılmakta ve modeller arasında uyumsuzluk tespit edildiğinde, sistem otomatik olarak bu durumu bir "review" uyarısı olarak işaretlemektedir. Üçüncü olarak, MI tespit edilen vakalarda, enfarktüsün anatomik lokalizasyonu beş bölge (AMI - Anterior MI, ASMI - Anteroseptal MI, ALMI - Anterolateral MI, IMI - Inferior MI, LMI - Lateral MI) üzerinden çoklu-etiketli bir sınıflandırma ile belirlenmektedir. Bu lokalizasyon görevi, yalnızca MI varlığı her iki model tarafından da onaylandığında (MI gate) devreye girmektedir. Sistemin dördüncü temel amacı, modellerin kararlarının açıklanabilir hale getirilmesidir. Bu kapsamda, CNN modelleri için Gradient-weighted Class Activation Mapping (Grad-CAM) tekniği kullanılarak, modelin hangi EKG segmentlerine odaklandığını gösteren temporal ısı haritaları üretilmektedir. Hibrit katmanda kullanılan XGBoost bileşeni için ise, SHAP (SHapley Additive exPlanations) değerleri hesaplanarak, her bir özneliliğin model kararına olan katkısı sayısal olarak gösterilmektedir. Beşinci olarak, sistemin üretim ortamında güvenilir bir şekilde çalışabilmesi için, fail-fast başlangıç doğrulamaları, etiket uzayı drift tespiti için fingerprint mekanizması ve XGBoost bileşeni için feature schema lock gibi güvenlik katmanları entegre edilmektedir.

Bu mekanizmalar, yanlış model-görev eşleşmelerinin, etiket tanımlarındaki değişikliklerin ve öznitelik uzayındaki sapmaların sistemin çalışması sırasında sessizce gerçekleşmesini engellemekte ve bu tür durumları proaktif olarak tespit ederek sistemi güvenli bir şekilde durdurabilmektedir.

Çalışmanın kapsamı, PTB-XL veri seti ile sınırlandırılmıştır. PTB-XL, PhysioNet platformu üzerinden açık erişimli olarak sunulan, 18,885 hastadan toplanan 21,837 adet 10-saniyelik 12-derivasyonlu EKG kaydını içeren ve her kaydın iki kardiyolog tarafından SCP-ECG standardına uygun şekilde etiketlendiği geniş ölçekli bir veri setidir [3] . Veri setinin stratified 10-fold cross-validation yapısı kullanılmış olup, fold 1-8 eğitim, fold 9 doğrulama ve fold 10 test seti olarak ayrılmıştır. Sistemin mimari tasarımı, üç ayrı CNN modelinin (superclass, binary MI ve MI lokalizasyon) sıralı orkestrasyonunu, CNN öznitelik çıkarımı üzerine inşa edilmiş XGBoost ensemble katmanını ve açıklanabilirlik bileşenlerini içermektedir.

Çalışmanın kapsamı dışında kalan bazı önemli sınırlamalar bulunmaktadır. İlk olarak, sistem yalnızca 12-derivasyonlu EKG kayıtları ile çalışacak şekilde tasarlanmıştır; 3-lead, 5-lead veya 6-lead gibi azaltılmış derivasyon sayılarına sahip EKG kayıtları desteklenmemektedir. İkinci olarak, sistem 100 Hz örnekleme frekansı ile eğitilmiştir; 500 Hz veya farklı frekanslarda kaydedilmiş EKG verilerinin kullanılabilmesi için yeniden örnekleme (resampling) işlemi gerekmektedir. Üçüncü olarak, posterior MI (PMI) lokalizasyonu, Phase-1 kapsamına dahil edilmemiştir; bu lokalizasyon tipi gelecek çalışmalarda ele alınacaktır. Dördüncü olarak, sistemin klinik validasyonu, gerçek hasta verileri üzerinde prospektif bir çalışma ile değil, PTB-XL test seti üzerinde retrospektif bir değerlendirme ile sınırlıdır. Son olarak, sistem, tıbbi bir "teşhis" aracı olarak değil, "klinik karar destek" sistemi olarak konumlandırılmıştır; nihai tanı ve tedavi kararının her zaman klinisyen sorumluluğunda olması gerekmektedir. Bu konumlandırma, hem etik hem de yasal açıdan (KVKK - Kişisel Verilerin Korunması Kanunu uyumluluğu) gerekli bir sınırlamadır.Özetle, bu çalışmanın kapsamı, tasarım ve planlama aşamalarını, sistem mimarisinin dokümantasyonunu, veri seti üzerinde eğitilmiş modellerin entegrasyonunu ve teorik olarak önerilen güvenlik mekanizmalarının tasarım seviyesinde dokümantasyonunu içermektedir. Sistemin tam implementasyonu, gerçek zamanlı API servislerinin geliştirilmesi ve kapsamlı test sonuçlarının elde edilmesi, çalışmanın sonraki aşamalarında gerçekleştirilecektir.

1.3 PROJENİN KATKILARI

Bu çalışma, EKG tabanlı MI tespiti ve lokalizasyonu alanında, teknik, metodolojik, açıklanabilirlik ve üretim güvenliği boyutlarında özgün katkılar sunmaktadır. Çalışmanın literatüre ve klinik uygulamalara sağlayacağı katkılar aşağıda detaylandırılmaktadır.

Teknik açıdan, çalışmanın en özgün katkısı, üç farklı CNN modelinin (superclass, binary MI ve MI lokalizasyon) sıralı orkestrasyonu ve bu modeller arasında tutarlılık doğrulama mekanizması (consistency guard) kurulmasıdır. Literatürdeki çoğu çalışma, tek bir modelin performansını optimize etmeye odaklanırken, bu çalışma, farklı görevler için uzmanlaşmış modellerin çıktılarının bir araya getirilerek daha güvenilir bir karar mekanizması oluşturulabileceğini göstermektedir. Consistency guard, superclass CNN'in MI tahmini ile binary MI CNN'in bağımsız doğrulamasını karşılaştırarak, dört farklı durum (AGREE_MI, AGREE_NO_MI, DISAGREE_TYPE_1, DISAGREE_TYPE_2) tanımlamakta ve bu durumların her birine farklı öncelik seviyeleri (HIGH, LOW, REVIEW) atamaktadır. Bu yaklaşım, modellerin uyumsuzluk gösterdiği durumlarda otomatik olarak klinisyen müdahalesini tetiklemekte ve böylece false positive oranlarını azaltarak klinik güvenilirliği artırmaktadır. Ayrıca, MI lokalizasyon modelinin yalnızca MI varlığı onaylandığında devreye girmesi (MI gate mekanizması), gereksiz hesaplama yükünü azaltmakta ve lokalizasyon tahminlerinin güvenilirliğini artırmaktadır.

Metodolojik olarak, çalışma, CNN tabanlı öznitelik çıkarımı ile XGBoost ensemble yönteminin birleştirildiği hibrit bir mimari önermektedir. CNN'in lokal patern öğrenme kapasitesi, XGBoost'un global karar sınırlarını optimize etme yeteneği ile harmanlanarak, her iki yaklaşımın güçlü yönlerinden faydalanılmaktadır. Ancak, bu çalışmanın özgün metodolojik katkısı, yalnızca hibrit mimarinin kullanılması değil, aynı zamanda bu mimaride ortaya çıkabilecek "sessiz hata" riskinin proaktif olarak yönetilmesidir. XGBoost bileşeni için geliştirilen feature schema lock mekanizması, CNN modelinin çıktı boyutunun, özniteliklerin sırasının veya ölçeklendirme parametrelerinin değişmesi durumunda sistemin otomatik olarak hata vermesini sağlamaktadır. Bu mekanizma, "feature_schema.json" adlı bir meta-veri dosyası ile CNN embedding boyutunun (64 boyut), öznitelik isimlerinin ve versiyon bilgilerinin kayıt altına alınmasını ve her çalışma zamanında bu bilgilerin doğrulanmasını içermektedir.

Açıklanabilirlik boyutunda, çalışma, XAI (Explainable AI) bileşenlerini sistemin sonradan eklenen opsiyonel bileşenleri olarak değil, sistem mimarisinin organik bir parçası olarak konumlandırmaktadır. Grad-CAM ve SHAP çıktıları, yalnızca analiz amaçlı üretilmekle kalmayıp, aynı zamanda bir artifact discovery mekanizması ile API yanıt sözleşmesine (AIResult v1.0 contract) entegre edilmektedir. Bu sayede, frontend uygulamaları veya raporlama sistemleri, XAI çıktılarına standart bir yapı üzerinden erişebilmekte ve bu çıktıları kullanıcılara sunabilmektedir. XAI bileşenlerinin sistem tasarımının başından itibaren contract-driven bir yaklaşımla entegre edilmesi, açıklanabilirlik araştırmalarının genellikle izole prototip aşamalarında kalması sorununa karşı özgün bir çözüm önermektedir. Üretim güvenliği açısından, çalışma, fail-fast başlangıç doğrulamaları, etiket uzayı drift tespiti için fingerprint mekanizması ve multi-head karışıklığını önleme stratejileri gibi bir dizi güvenlik katmanı tanımlamaktadır. Fail-fast yaklaşımı, sistem başlatılırken tüm model checkpoint'lerinin beklenen görevlerle uyumlu olup olmadığını doğrulamakta ve örneğin, 2-boyutlu temporal regression head'inin yanlışlıkla 5-sınıflı MI lokalizasyon görevi için kullanılmasını engellemektedir. Etiket uzayı fingerprint'i (8ab274e06afa1be8), MI lokalizasyon etiketlerinin türetildiği SCP kod eşleştirmesinin değişip değişmediğini tespit etmekte ve eğer modelin eğitildiği etiket uzayı ile üretim ortamındaki etiket uzayı farklılaşmışsa, sistemin otomatik olarak hata vermesini sağlamaktadır. Bu tür proaktif güvenlik mekanizmalarının sistematik bir şekilde entegre edilmesi, tıbbi AI sistemlerinin üretim ortamında karşılaşılabileceği riskler konusunda literatürde sınırlı sayıda çalışma bulunması nedeniyle, önemli bir katkı oluşturmaktadır. Klinik açıdan, çalışmanın sağlayacağı en önemli katkı, çoklu doğrulama mekanizmaları sayesinde false positive oranlarının azaltılması ve böylece klinisyenlerin gereksiz yere ek tetkiklere yönlendirilmesinin önlenmesidir. Consistency guard mekanizmasının ürettiği DISAGREE uyarıları, özellikle sınır durumlarında modelin güven düzeyinin düşük olduğu vakaları açıkça işaretlemekte ve bu vakalarda klinisyenin dikkatini çekmektedir.

Sonuç olarak, bu çalışma, yalnızca yüksek performanslı bir EKG sınıflandırma modeli geliştirmenin ötesine geçerek, klinik güvenilirlik, açıklanabilirlik ve üretim ortamında operasyonel dayanıklılık gereksinimlerini entegre eden bütüncül bir sistem tasarımı sunmaktadır. Çalışmanın teknik, metodolojik ve klinik katkıları, EKG tabanlı AI sistemlerinin gerçek dünya uygulamalarına geçiş sürecinde karşılaşılan zorlukların ele alınmasına yönelik özgün çözümler içermektedir.

2 KAYNAK ARAŞTIRMASI

Elektrokardiyografi (EKG) sinyallerinin otomatik yorumlanması ve kardiyak patolojilerin yapay zeka destekli tespiti, son on yılda tıbbi sinyal işleme ve makine öğrenmesi alanlarının en aktif araştırma konularından biri haline gelmiştir. Bu bölümde, özellikle miyokard enfarktüsü (MI) tespiti ve lokalizasyonu, derin öğrenme mimarileri, hibrit yaklaşımlar, açıklanabilir yapay zeka (XAI) ve klinik karar destek sistemlerinde üretim güvenilirliği konularında yapılan çalışmalar sistematik olarak incelenmektedir. Literatür taraması, geleneksel sinyal işleme yöntemlerinden başlayarak, derin öğrenme devrimine, güncel hibrit mimarilere ve üretim ortamında karşılaşılan güvenilirlik sorunlarına kadar geniş bir spektrumu kapsamaktadır. Her alt bölümde, ilgili çalışmaların güçlü yönleri, sınırlılıkları ve bu projenin literatürdeki konumlanması eleştirel bir bakış açısıyla değerlendirilmektedir.

2.2 EKG SİNYALİ SINIFLANDIRMASINDA DERİN ÖĞRENME YAKLAŞIMLARI

Kardiyovasküler hastalıkların dünya çapında ölüm nedenlerinin başında geldiği göz önüne alındığında, EKG sinyallerinin otomatik yorumlanması hem klinik iş yükünü azaltma hem de erken teşhis doğruluğunu artırma potansiyeli taşımaktadır [3]. Geleneksel EKG analiz yöntemleri, QRS kompleksi, P dalgası ve T dalgası gibi karakteristik noktaların manuel segmentasyonuna ve el yapımı öznitelik çıkarımına dayanmaktaydı. Bu yaklaşımlar, uzman kardiyologların klinik deneyimlerinden türetilmiş kural tabanlı sistemler veya istatistiksel öznitelikler (dalga genişlikleri, amplitüdler, spektral özellikler) üzerine inşa edilmiş klasik makine öğrenmesi algoritmaları (Destek Vektör Makineleri, Rastgele Orman) kullanmaktaydı. Ancak, bu yöntemler özellikle MI gibi karmaşık patolojilerde, zamanla değişen morfolojik farklılıklar, hasta-spesifik varyasyonlar ve gürültü nedeniyle sınırlı bir başarı sunmaktaydı. Ayrıca, manuel öznitelik çıkarımı süreci, hem zaman alıcı hem de uzman bilgisine bağımlı olup, farklı veri setlerine genelleme kapasitesi düşüktü [4].

Derin öğrenmenin EKG analizine adaptasyonu, bu sınırlamaların aşılmasında devrim niteliğinde bir etki yaratmıştır. Evrişimsel sinir ağları (CNN), EKG gibi zaman serisi verilerinde yerel örüntüleri otomatik olarak öğrenme kapasitesi sayesinde, özellik çıkarımı aşamasını elimine ederek doğrudan ham sinyalden öğrenmeyi mümkün kılmıştır. Nitekim, 1-boyutlu CNN mimarilerinin, çok katmanlı tasarımlarla 12 farklı aritmi tipinde %97.03 doğruluk elde ettiği gösterilmiştir. Bu çalışmada, 7 katmanlı bir 1D-CNN mimarisi kullanılmış ve her katmanda farklı filtre boyutları (16, 32, 64, 128) ile hiyerarşik öznitelik öğrenme gerçekleştirilmiştir. Model, PTB-XL veri seti üzerinde eğitilmiş ve özellikle atriyoventriküler blok (AVB) ve atriyal fibrilasyon (AFIB) gibi aritmi tiplerinde yüksek duyarlılık göstermiştir. Ancak, bu çalışmanın bir sınırlılığı, yalnızca aritmi sınıflandırması üzerine odaklanması ve MI gibi iskemik kalp hastalıklarının tespitinde performansının değerlendirilmemiş olmasıdır.

Bununla birlikte, CNN'lerin yerel öznitelik çıkarımındaki üstünlüğüne karşın,

uzun vadeli zamansal bağımlılıkları yakalamada sınırlamaları mevcuttur. EKG sinyallerinde, bir kardiyak döngünün farklı fazları (P dalgası, QRS kompleksi, T dalgası) arasındaki zamansal ilişkiler, bazı patolojilerin tespiti için kritik önem taşımaktadır. Örneğin, P-R intervali uzaması, atriyal depolarizasyon ile ventriküler depolarizasyon arasındaki gecikmeyi gösterir ve bazı ileti sistemleri bozukluklarının erken belirticidir. Bu boşluğu doldurmak amacıyla, Long Short-Term Memory (LSTM) ve Transformer tabanlı mimariler, EKG sinyallerinde sıralı bağımlılıkları modellemek için önerilmiştir. LSTM'ler, gating mekanizmaları (unutma kapısı, girdi kapısı, çıktı kapısı) sayesinde uzun vadeli bağımlılıkları öğrenebilme kapasitesine sahip olsa da, uzun sekansların işlenmesinde hesaplama maliyeti yüksektir ve gradyan kaybolması (vanishing gradient) sorununa karşı tam bir çözüm sunamamaktadır [4].

Transformer mimarileri ise, self-attention mekanizması ile tüm zaman adımları arasında global ilişkileri doğrudan modelleyebilmektedir. Attention mekanizması, her bir zaman adımının diğer tüm zaman adımlarıyla olan ilişkisini öğrenerek, uzun menzilli zamansal bağımlılıkları paralel olarak işleyebilmektedir. Ancak, Transformer'ların büyük veri seti gereksinimleri ve hesaplama kaynak talebi, sınırlı veri setlerinde uygulanabilirliğini zorlaştırmaktadır. Bir çalışmada, pure Transformer mimarisinin PTB-XL veri seti üzerinde CNN'den daha düşük performans gösterdiği, ancak CNN ile birleştirildiğinde (hibrit mimari) optimal sonuçlar elde edildiği rapor edilmiştir [5].

CNN ve Transformer bileşenlerinin birleştirildiği hibrit mimariler, hem yerel hem de global örüntülerin eşzamanlı öğrenilmesini sağlamaktadır. Bir çalışmada, Stockwell dönüşümü ile frekans domain öznetelik çıkarımının ardından CNN-Transformer hibrit modeli, aritmi sınıflandırmasında geleneksel CNN ve LSTM modellerini aşan bir performans sergilemiştir [5]. Bu hibrit yaklaşımın temel avantajı, CNN'in lokal patern algılama gücünü Transformer'ın uzun menzilli bağımlılık modelleme yeteneğiyle harmanlayarak, EKG sinyalinin çok ölçekli yapısını daha etkili bir şekilde temsil edebilmesidir. Özellikle, ST-T segment değişikliklerinin tespitinde, Transformer'ın global konteksti değerlendirme yeteneği, yalnızca lokal özelliklere odaklanan CNN'lerden belirgin üstünlük sağlamıştır.

Ancak, bu çalışmanın da sınırlılığı, model karmaşıklığının artması nedeniyle yorumlanabilirliğin azalması ve klinik ortamda hesaplama kaynaklarının sınırlı olduğu

durumlarda uygulanabilirlik sorunlarıdır. Hibrit modellerin eğitim süresi, sade CNN modellerine kıyasla 2-3 kat daha uzun olabilmekte ve inference latency artışı, gerçek zamanlı klinik uygulamalarda sorun yaratabilmektedir. Ayrıca, hibrit modellerin farklı bileşenlerinin (CNN, Transformer) hiperparametre optimizasyonu, tek tip modellere kıyasla daha zorlu bir süreçtir. Bu çalışmalar, derin öğrenme yaklaşımlarının EKG sınıflandırmasında yüksek doğruluk oranlarına ulaşabileceğini göstermektedir. Ancak, çoğu çalışma, tek bir modelin performansını maksimize etmeye odaklanmakta ve modelin farklı patoloji tipleri veya hasta grupları üzerindeki güvenilirliği, uyumsuzluk durumlarında nasıl davrandığı ve üretim ortamındaki operasyonel dayanıklılığı konularında sınırlı bilgi sunmaktadır. Bu proje, bu boşluğu doldurmak amacıyla, farklı görevler için uzmanlaşmış çoklu modellerin orkestrasyonu ve bu modeller arasında tutarlılık kontrolü yaklaşımını benimsemektedir.

2.3 MİYOKARD ENFARKTÜSÜ TESPİTİ VE ANATOMİK LOKALİZASYON

MI'nin erken ve doğru tespiti, hasta prognozu ve tedavi planlaması açısından hayati önem taşımaktadır. Geleneksel klinik yaklaşımda, kardiyologlar Q dalgası, ST segment elevasyonu ve T dalgası inversiyonu gibi EKG belirteçlerini değerlendirerek MI lokalizasyonunu tahmin etmektedir. Bu belirteçler, koroner arterlerdeki tıkanıklığın kalbin hangi bölgesini etkilediğini dolaylı olarak göstermekte ve acil müdahale stratejisinin belirlenmesinde kritik rol oynamaktadır. Örneğin, II, III ve aVF derivasyonlarındaki ST elevasyonu inferior MI'yi işaret ederken, V1-V4 derivasyonlarındaki değişiklikler anterior MI'yi göstermektedir. Ancak, bu yöntem özellikle çoklu damar bölgesini etkileyen MI'lerde düşük duyarlılık göstermektedir [1]. Wang ve arkadaşlarının (2025) yaptığı kapsamlı bir çalışmada, deneyimli kardiyologların görsel EKG değerlendirmesinde, özellikle left circumflex (LCX) bölgesinde %15 gibi düşük bir duyarlılık, çoklu damar tutulumunda (double vessel disease, DVD) %24 ve üç damar tutulumunda (triple vessel disease, TVD) %4 gibi kabul edilemez düzeyde düşük doğruluklar saptanmıştır. Bu bulgular, manuel değerlendirmenin insan kaynaklı yorgunluk, deneyim farklılıkları ve subjektif yorum faktörlerinden etkilendiğini ve özellikle karmaşık vakalarda güvenilirliğinin ciddi ölçüde düştüğünü ortaya koymaktadır.

Yapay zeka destekli yaklaşımlar, bu sınırlamaları aşmada belirgin avantajlar sunmaktadır. Wang ve arkadaşları (2025), biyosimülasyon modeli kullanarak eğitilen AI-MI-12ECG adlı bir derin öğrenme modeli geliştirmiş ve bu modelin, 182 MI hastasında geç gadolinyum tutulumu (LGE) CMR ile karşılaştırıldığında, LAD (Left Anterior Descending), RCA (Right Coronary Artery) ve LCX bölgelerinde sırasıyla 0.95, 0.97 ve 0.91 doğruluk elde ettiğini göstermiştir. Modelin özellikle dikkat çekici yönü, transmembran potansiyel (TMP) yeniden yapılandırması yoluyla MI lokalizasyonunu 17-segment kalp modelinde (AHA segmentasyon modeli) haritalayabilmesidir. Bu yaklaşım, 50-150 elektrot gerektiren geleneksel elektrokardiyografik görüntüleme (ECGi) sistemlerine kıyasla, yalnızca standart 12-derivasyonlu EKG kullanarak septal fibrozis tespitinde dahi yüksek doğruluk sağlamıştır.

Ancak, bu çalışmanın bir sınırlılığı, hasta kohortunun görece küçük olması (182 hasta) ve modelin farklı hasta demografileri, komorbidite profilleri (diyabet, hipertansiyon, kronik böbrek yetmezliği) ve farklı hastane ortamlarındaki EKG cihazlarına genelleme kapasitesinin yeterince test edilmemiş olmasıdır. Ayrıca, biyosimülasyon modelleri (örneğin, kalp elektrofizyolojisi simülasyonu) gerçek hasta varyasyonlarının tamamını yansıtmayabilir ve modelin sentetik verilere aşırı uyum sağlama (overfitting) riski mevcuttur [1]. Başka bir sınırlama, modelin akut MI ile kronik MI (eski enfarkt skarı) arasındaki ayrımı yapma kapasitesinin değerlendirilmemiş olmasıdır; bu klinik pratikte önemli bir ayrım olup, tedavi yaklaşımını doğrudan etkiler.

Anatomik lokalizasyon görevinde, multi-label sınıflandırma yaklaşımları özellikle önem taşımaktadır. Zira bir hastada aynı anda birden fazla anatomik bölgede MI bulunabilmektedir. PTB-XL veri setinde, inferior MI (IMI: 2,685 kayıt) ve anteroseptal MI (ASMI: 2,363 kayıt) en sık görülen lokalizasyon tipleridir [3]. Bu veri setinin sunduğu hiyerarşik etiket yapısı (superclass: MI, subclass: AMI, ASMI, ALMI, IMI, LMI), modellerin hem genel MI tespiti hem de ince taneli lokalizasyon görevlerinde değerlendirilmesine olanak tanımaktadır. Ancak, literatürdeki çoğu çalışma, ya yalnızca MI varlığını tespit etmekte (binary classification) ya da lokalizasyonu tek-etiketli bir problem olarak ele almaktadır [1].

Çoklu-etiketli lokalizasyon yaklaşımları, daha gerçekçi klinik senaryoları yansıtmasına rağmen, model eğitiminde dengesiz sınıf dağılımı (örneğin, posterior MI'nın nadir görülmesi: ~400 kayıt) ve bazı SCP kodlarının birden fazla anatomik bölgeye karşılık gelmesi (örneğin, ILMI - inferolateral MI'nın hem IMI hem de LMI bileşenleri içermesi) gibi zorluklar yaratmaktadır. Bu proje, literatüre katkısı, MI tespitini iki bağımsız model (superclass ve binary MI) ile çapraz doğrulama yaparak güvenilirliği artırması ve lokalizasyon görevini yalnızca MI varlığı onaylandığında devreye alan gating mekanizması ile gereksiz false positive lokalizasyon tahminlerini önlemesidir. Ayrıca, PTB-XL'deki SCP kodlarının 5 anatomik bölgeye türetilmesi (derived labeling) sürecinin dokümanite edilmesi ve bu etiket uzayının bir fingerprint ile korunması, literatürde nadiren ele alınan bir etiket yönetimi yaklaşımı sunmaktadır.

2.4 PTB-XL VERİ SETİ: STANDARTLAŞMA VE BENCHMARK ROLÜ

Makine öğrenmesi algoritmalarının geliştirilmesinde en büyük engellerden biri, büyük ölçekli, çeşitli ve açık erişimli veri setlerinin eksikliğidir. PTB-XL veri seti, bu açığı kapatmak amacıyla Wagner ve arkadaşları (2020) tarafından sunulmuştur. Veri seti, 18,885 hastadan alınan 21,837 adet 10-saniyelik 12-derivasyonlu EKG kaydını içermekte olup, her kayıt iki kardiyolog tarafından SCP-ECG standardına (Standardized Communication Protocol for Computer Assisted Electrocardiography) uygun şekilde 71 farklı tanı ifadesi ile çoklu etiketlenmiştir. Veri setinin en ayırt edici özelliklerinden biri, hiyerarşik etiket organizasyonudur: 5 ana sınıf (NORM: normal, CD: kardiyak hastalık, MI: miyokard enfarktüsü, HYP: hipertrofi, STTC: ST-T değişiklikleri) ve 24 alt sınıf. Bu yapı, araştırmacıların farklı detay seviyelerinde sınıflandırma modelleri geliştirmelerine imkan tanımakta ve hem genel patoloji taraması hem de spesifik alt-tip tespiti görevlerinin aynı veri seti üzerinde karşılaştırılmasını mümkün kılmaktadır [3].

PTB-XL'in bir diğ er g    l   yanı, ger  ek d  nya ko  ullarını yansıtan sinyal kalitesi   e  itliliğidir. Kayıtların %77.01'i en y  ksek kalitedeyken (quality=high), geri kalan kısımda baseline drift (izoelektrik   izginin kayması), elektriksel g  r  lt   (50/60 Hz powerline interference), kas artefaktları (EMG g  r  lt  s  ) ve elektrot problemleri (zayıf temas, hareketli elektrot) gibi artefaktlar bulunmaktadır [3]. Bu   e  itlilik, makine   ğrenmesi algoritmalarının klinik ortamda kar  ıla  abileceğ i değ  i  ken ko  ullara kar  şı dayanıklılığının (robustness) test edilmesinde kritik   neme sahiptir. Ger  ek klinik ortamda, t  m EKG kayıtlarının optimal kalitede olması beklenemez; hasta hareketi, elektrot yerle  im hataları ve cihaz kalibrasyonu sorunları sıklıkla g  r  lmektedir.

Nitekim, stratified 10-fold cross-validation   nerileriyle birlikte sunulan bu veri seti, literat  rde bir benchmark referansı haline gelmi  tir. Veri setinin a  ık eri  imli olması ve PhysioNet platformu   zerinden   cretsiz sunulması, farklı ara  tırma gruplarının sonu  larını kar  ıla  tırılabilir bir   ekilde raporlaması b  y  k avantaj saėlamaktadır. Wagner ve arkadaşları , her fold i  in hasta bazında ayır  tırma yapmı   (patient-wise split), b  ylece aynı hastanın kayıtlarının hem eėitim hem de test setinde bulunması ve veri sızıntısı (data leakage) riskini   nlemi  lerdir. Bu,   zellikle ger  ek  i performans deėerlendirmesi i  in kritik   nem ta  ımaktadır.

PTB-XL   zerine yapılan   alı  malar,   e  itli derin   ğrenme mimarilerinin performansını kar  ıla  tırmalı olarak ortaya koymu  tur.   rneğ  n, ResNet ve Inception gibi mimarilerin transfer   ğrenme ile k    k veri setlerinde umut verici sonu  lar verdiė i, ancak geni   veri setlerinde scratch'ten eėitimin daha etkin olabileceė i g  sterilmi  tir [5]. Bu bulgular, veri setinin b  y  kl  ğ  n  n ve   e  itliliğ  nin, model se  imi ve eėitim stratejisi   zerindeki etkisini vurgulamaktadır. Transfer   ğrenme,   zellikle ImageNet gibi g  rsel veri setleri   zerinde   n-eėitilmi   modellerin 1D EKG sinyallerine adaptasyonu baėlamında tartı  malı bir konudur; zira g  rsel   znitelikler ile temporal EKG   zellikleri arasında doėrudan bir benzerlik bulunmamaktadır [4].

Bununla birlikte, PTB-XL'in bazı sınırlılıkları da mevcuttur. Veri seti, aėırlıklı olarak Avrupa pop  lasyonundan (Almanya) toplanmı   olup, farklı etnik gruplar ve

coğrafi bölgelerdeki hasta demografilerini yeterince temsil etmeyebilir. Özellikle Afrika, Asya ve Latin Amerika popülasyonlarında EKG paternlerinin farklılık gösterebileceği bilinmektedir (örneğin, erken repolarizasyon paterninin prevalansı etnik gruplara göre değişir). Ayrıca, bazı nadir patolojilerin (örneğin, posterior MI: ~400 kayıt) kayıt sayısı düşüktür ve bu durum, dengesiz sınıf dağılımı nedeniyle model eğitiminde zorluklar yaratmaktadır. Etiketleme sürecinde, iki kardiyolog arasındaki uyumsuzlukların nasıl çözüldüğü ve etiket güvenilirlik skorlarının (likelihood scores: 0, 50, 100) yorumlanması konuları, bazı belirsizlikler içermektedir. Wagner ve arkadaşları, uyumsuzluk durumunda üçüncü bir uzmanın devreye girdiğini belirtmekle birlikte, bu sürecin detayları net değildir.

Bu proje, PTB-XL'i temel veri kaynağı olarak kullanmakta, ancak etiket türetme sürecini (derived labeling) açıkça dokümanate ederek ve label space fingerprint mekanizması ile etiket bütünlüğünü koruyarak, bu belirsizlikleri azaltmayı hedeflemektedir. Özellikle, SCP kodlarından anatomik lokalizasyon etiketlerine eşleştirme (mapping) sürecinin versiyonlanması ve değişikliklerin izlenebilirliği, üretim ortamında etiket tutarlılığını garanti etmek için kritik önem taşımaktadır.

2.5 HİBRİT MİMARİ YAKLAŞIMLAR: CNN VE XGBOOST ENTEGRASYONU

CNN'lerin öznetelik çıkarımındaki başarısının, ağaç tabanlı gradient boosting algoritmaları ile birleştirilmesi, son yıllarda dikkat çeken bir yaklaşım olmuştur. XGBoost (Extreme Gradient Boosting), yüksek boyutlu öznetelik uzaylarında doğrusal olmayan etkileşimleri modellemede, dengesiz veri setlerinde dayanıklılık göstermede ve kalibre edilmiş tahminler üretmede güçlü bir performans sergilemektedir. Hibrit CNN-XGBoost pipeline'ı, CNN'in lokal patern öğrenme kapasitesini, XGBoost'un global karar sınırlarını optimize etme yeteneği ile harmanlayarak, hem doğruluk hem de yorumlanabilirlik açısından avantaj sağlamaktadır [2]. CNN, ham sinyalden otomatik olarak öznetelik çıkarırken (representation learning), XGBoost bu öznetelikler üzerinde ensemble öğrenme yaparak, bireysel ağaçların zayıf yönlerini telafi etmekte ve robust bir sınıflandırıcı oluşturmaktadır.

Literatürdeki bazı çalışmalar, CNN ile çıkarılan özneteliklerin (örneğin, son fully connected katmanından önceki embedding vektörü) XGBoost veya diğer gradient

boosting yöntemlerine (LightGBM, CatBoost) girdi olarak verilmesinin, yalnızca CNN kullanan modellere kıyasla özellikle dengesiz veri setlerinde daha iyi sonuçlar verdiğini göstermiştir . XGBoost'un ağaç tabanlı yapısı, kategorik öznitelikleri doğrudan işleyebilmesi, eksik veri ile başa çıkabilmesi (missing value handling) ve aşırı öğrenmeyi (overfitting) önlemek için düzenlileştirme (regularization) parametreleri (alpha, lambda) sunması gibi avantajlar sağlamaktadır. Ayrıca, XGBoost'un ürettiği tahminler, sigmoid veya softmax fonksiyonları ile CNN'in çıktıları ile birleştirilerek (ensemble stacking), her iki modelin güçlü yönlerinden faydalanılabilmektedir. Ancak, hibrit sistemlerin dezavantajı, model karmaşıklığının artması, iki farklı bileşenin hiperparametre optimizasyonunun ayrı ayrı yapılması gerekliliği (örneğin, CNN için learning rate, dropout; XGBoost için max_depth, n_estimators) ve üretim ortamında iki ayrı modelin senkronizasyonunun yönetilmesi zorluklarıdır. Pipeline'da CNN'in embedding'lerinin boyutu değiştiğinde, XGBoost modelinin yeniden eğitilmesi gerekir; aksi takdirde feature mismatch hatası oluşur.

Ancak hibrit sistemlerin üretim ortamında kullanımında kritik bir risk faktörü bulunmaktadır: "silent failure". XGBoost, girdi özniteliklerinin yanlış sırada, yanlış ölçekte veya yanlış boyutta olması durumunda çoğu zaman hata vermez; yalnızca mantıksız skorlar üretir. Bu durum, CNN backbone'unun değişmesi (örneğin embedding boyutunun 64'ten 128'e çıkması), öznitelik sırasının permüte edilmesi (örneğin, feature_0 ve feature_1'in yer değiştirmesi) veya StandardScaler'ın farklı bir veri seti üzerinde fit edilmiş olması gibi senaryolarda ortaya çıkabilir [2]. Örneğin, eğitim sırasında scaler, eğitim setinin mean ve std değerleri ile fit edilmişse, ancak üretim ortamında farklı bir scaler kullanılırsa, öznitelikler yanlış normalize edilir ve XGBoost mantıksız tahminler üretir.

Literatürde, hibrit modellerin performans avantajları sıklıkla vurgulanırken, bu tür üretim ortamı risklerinin sistematik bir şekilde yönetilmesi konusu ihmal edilmektedir. Bazı çalışmalar, model versiyonlama ve meta-veri yönetimi konularına değinse de, öznitelik uzayının bütünlüğünü garanti eden mekanizmalar (örneğin, feature schema lock, feature name validation) nadiren uygulanmaktadır [6] .

Bu proje, hibrit CNN-XGBoost mimarisini benimserken, aynı zamanda üretim güvenilirliği için feature schema doğrulama mekanizması entegre etmektedir. Her

XGBoost modeli için, eğitim sırasında kullanılan CNN embedding boyutu, öznitelik isimleri ve scaler parametreleri (mean, std) bir "feature_schema.json" dosyası ile kaydedilmekte ve çalışma zamanında (runtime) bu bilgiler doğrulanmaktadır. Bu yaklaşım, literatürdeki hibrit model çalışmalarından farklılaşarak, yalnızca performans değil aynı zamanda operasyonel güvenlik boyutunu da ele almaktadır.

2.6 AÇIKLANABİLİR YAPAY ZEKA (XAI) VE KLİNİK KARAR DESTEK SİSTEMLERİ

Yapay zeka sistemlerinin klinik ortamda kabul görmesindeki en büyük engellerden biri, "kara kutu" doğasıdır. Sağlık profesyonelleri, modelin hangi bilgilere dayanarak karar verdiğini anlamadan, bu kararları klinik uygulamada kullanma konusunda tereddüt yaşamaktadır [7]. Bu bağlamda, açıklanabilir yapay zeka teknikleri, modelin karar mekanizmasını görselleştirerek klinisyenlere şeffaflık sağlamaktadır. XAI, yalnızca modelin "ne kadar doğru" olduğunu değil, aynı zamanda "neden bu kararı verdiğini" açıklayarak, klinisyenlerin modele olan güvenini artırmakta ve hatalı tahminlerin tespit edilmesini kolaylaştırmaktadır. Özellikle tıbbi malpraktis davalarında, AI sisteminin kararlarının açıklanabilir olması, yasal sorumluluk açısından kritik önem taşımaktadır.

Gradient-weighted Class Activation Mapping (Grad-CAM), CNN tabanlı modellerde en yaygın kullanılan XAI yöntemlerinden biridir. Grad-CAM, modelin son konvolüsyon katmanındaki aktivasyonlar ile sınıf skorlarının gradyanlarını birleştirerek, girdi sinyalinin hangi bölgelerinin karar için kritik olduğunu gösteren bir ısı haritası üretir. EKG bağlamında, Grad-CAM'ın anterior veya inferior derivasyonlardaki kritik bölgeleri (örneğin, ST segmenti, Q dalgası) vurgulaması, klinisyenlerin modelin kararını doğrulama sürecini kolaylaştırmaktadır [1]. Örneğin, bir MI tespitinde, Grad-CAM'ın V2-V4 derivasyonlarının ST segmentinde yüksek aktivasyon göstermesi, modelin klinik olarak anlamlı özelliklere odaklandığını gösterir. Ancak, Grad-CAM'ın bazı sınırlılıkları vardır: düşük uzamsal çözünürlük (özellikle derin ağlarda, son konvolüsyon katmanının çıktısı küçük boyutta olduğundan detay kaybı oluşur), yalnızca pozitif katkıları vurgulama (negatif kanıtları, yani "bu bölgede MI belirtisi yok" bilgisini göstermeme) ve bazı durumlarda artefaktlara veya gürültülü bölgelere odaklanma.

Bu nedenle, Grad-CAM çıktılarının "sanity check" testleri ile doğrulanması önerilmektedir; örneğin, modelin ağırlıkları rastgele başlatıldığında (randomization test) Grad-CAM'ın anlamlı bölgeleri vurgulamaya devam etmesi, yöntemin güvenilirliğini

sorguladır. Eğer rastgele bir model de aynı bölgeleri vurguluyorsa, Grad-CAM gerçek model davranışını yansıtmıyor demektir. Hibrit sistemlerde ise, XGBoost bileşeni için SHAP (SHapley Additive exPlanations) değerleri kullanılmaktadır. SHAP, oyun teorisindeki Shapley değerlerinden türetilmiş bir yöntemdir ve her bir özneliğin model çıktısına olan katkısını matematiksel olarak adil bir şekilde dağıtarak, hangi embedding boyutlarının kararı en çok etkilediğini sayısal olarak göstermektedir. SHAP, model-agnostic bir yöntem olup, herhangi bir makine öğrenmesi modeline uygulanabilir; ancak, ağaç tabanlı modeller için optimize edilmiş TreeExplainer algoritması, özellikle hızlı ve doğru sonuçlar sunmaktadır. TreeExplainer, XGBoost'un ağaç yapısını doğrudan kullanarak, her bir özneliğin katkısını hesaplar ve bu süreç, LIME gibi pertürbasyon tabanlı yöntemlere kıyasla çok daha hızlıdır. Grad-CAM ve SHAP'ın birlikte kullanımı, çok modaliteli açıklanabilirlik sağlayarak, hem görsel (ısı haritası) hem de sayısal (feature importance) kanıt sunmaktadır. Bir çalışmada, bu kombinasyonun, radyologların modele olan güvenini %27 oranında artırdığı ve karar verme süresini %13 kısalttığı rapor edilmiştir. Ancak, bu çalışmanın sınırlılığı, güven artışının subjektif anketlerle ölçülmesi (Likert scale) ve gerçek klinik karar süreçlerinde XAI'nin pratik faydasının uzun vadeli bir şekilde değerlendirilmemiş olmasıdır. Prospektif randomize kontrollü çalışmalar (RCT), XAI'nin klinik sonuçlar üzerindeki gerçek etkisini değerlendirmek için gereklidir. Bununla birlikte, XAI tekniklerinin güvenilirliği de sorgulanmalıdır. Grad-CAM'ın ürettiği ısı haritalarının, modelin gerçekte kullandığı bilgileri yansıtmadığı, "sanity check" mekanizmaları ile doğrulanmalıdır. Özellikle, modelin etiket uzayında veya veri dağılımında meydana gelen drift durumlarında, XAI çıktılarının tutarlılığının izlenmesi, üretim güvenilirliği açısından kritik öneme sahiptir. Bu proje, XAI bileşenlerini sistemin opsiyonel eklentileri olarak değil, sistem mimarisinin organik bir parçası olarak konumlandırmakta ve artifact discovery mekanizması ile API yanıt sözleşmesine (AIResult contract) entegre etmektedir. Bu yaklaşım, XAI'nin yalnızca araştırma amaçlı değil, üretim ortamında operasyonel bir bileşen olarak kullanılabilirliğini artırmaktadır.

2.7 ÜRETİM SİSTEMLERİNDE MODEL İZLEME VE GÜVENİLİRLİK

CardioGuard-AI gibi çok modelli sistemlerde, drift izleme ek katmanlar gerektirmektedir. Her bir modelin (superclass, binary MI, localization) çıktı

dağılımlarının izlenmesine ek olarak, etiket uzayı fingerprint doğrulaması da yapılmalıdır. Örneğin, MI lokalizasyon modelinin eğitildiği SCP kod-bölge eşleşmesi değişirse (örneğin, IPLMI'nın artık IMI, LMI ve PMI'ya eşleştirilmesi yerine yalnızca IMI ve LMI'ya eşleştirilmesi), modelin üretim ortamındaki çıktıları artık geçersiz hale gelecektir. Bu durumda, model teknik olarak çalışmaya devam edebilir ancak semantik olarak yanlış sonuçlar üretir. Bu nedenle, `mapping_fingerprint` gibi versiyonlama mekanizmalarının entegrasyonu, üretim güvenilirliği için vazgeçilmezdir. Etiket uzayının bir hash değeri (örneğin, SHA-256) ile korunması ve her inference sırasında bu hash'in doğrulanması, bu tür sessiz hataları önleyebilir.

Ancak, literatürde çoklu model orkestrasyonu kullanan sistemlerde drift izleme stratejileri yeterince ele alınmamıştır; çoğu çalışma, tek bir modelin drift'ini izlemeye odaklanmaktadır [6]. Çok modellenli sistemlerde, bir modelin drift'i diğer modellerin performansını etkileyebilir. Örneğin, superclass modelinde drift oluşursa ve MI sınıfını daha sık tahmin etmeye başlarsa, lokalizasyon modeline daha fazla yük biner ve false positive lokalizasyonlar artabilir. Bu nedenle, modeller arası etkileşimlerin izlenmesi ve uyumsuzluk oranlarının (disagreement rate) takip edilmesi, sistem seviyesinde drift tespiti için gereklidir.

Otomasyonun model yaşam döngüsü yönetimindeki rolü de vurgulanmalıdır. MLOps pratikleri, model izleme, yeniden eğitim ve dağıtım süreçlerini otomatize ederek, drift tespiti sonrası müdahale süresini kısaltmaktadır. Otomatik uyarılar ve eşik tabanlı tetikleyiciler (threshold-based triggers), veri bilimi ekiplerinin manuel gözleminden daha hızlı tepki verilmesini sağlamak ve kritik tıbbi uygulamalarda hasta güvenliğini korumaktadır [6]. Örneğin, prediction drift $PSI > 0.2$ eşiğini aştığında, otomatik olarak Slack veya e-posta bildirimi gönderilebilir ve model performansı daha detaylı analiz için işaretlenebilir.

Ancak, otomasyon süreçlerinin kendisi de hatalara açıktır; örneğin, yanlış yapılandırılmış bir otomatik yeniden eğitim pipeline'ı, performansı düşük bir modeli üretim ortamına dağıtabilir veya yanlış veri seti ile eğitim yapabilir. Bu nedenle, insan-

in-the-loop (HITL) yaklaşımları, kritik kararlarda insan onayını gerekli kılarak, otomasyon risklerini azaltmaktadır. Örneğin, yeniden eğitilmiş bir modelin üretim ortamına dağıtımından önce, veri bilimcilerinin ve klinik uzmanların validation metriklerini incelemesi ve onaylaması gerekebilir. Ayrıca, canary deployment veya blue-green deployment stratejileri, yeni modelin önce küçük bir kullanıcı grubunda test edilmesini sağlayarak, potansiyel hataların tüm sistemi etkilemesini önler [8] .

Üretim ortamında model güvenilirliğinin bir diğer boyutu, sistem dayanıklılığıdır (resilience). Bir modelin tamamen başarısız olması durumunda (örneğin, model dosyasının bozulması, dependency versiyonlarının uyuşmaması), sistemin nasıl davranacağı önceden tanımlanmalıdır. Fallback mekanizmaları, örneğin daha basit bir rule-based sisteme geçiş veya "model not available" mesajı ile kullanıcıyı bilgilendirme, kritik sağlık uygulamalarında hasta güvenliğini korumak için gereklidir. Bu proje, fail-fast startup davranışı ve comprehensive logging mekanizmaları ile, üretim ortamında oluşabilecek hataların hızlı tespit edilmesini ve müdahale edilmesini hedeflemektedir.

2.8 BU PROJENİN LİTERATÜRDEKİ KONUMLANDIRMASI

Literatür incelemesi, EKG tabanlı MI tespiti ve lokalizasyonu alanında önemli ilerlemeler kaydedildiğini göstermekle birlikte, bazı kritik boşlukların hala mevcut olduğunu ortaya koymaktadır.

İlk olarak, çoğu çalışma tek bir modelin performansına odaklanmakta, çok modelli pipeline'ların tutarlılık doğrulaması ve uyuşmazlık yönetimi konularında yeterli derinlik sağlamamaktadır [4]. CardioGuard-AI'nin önerdiği "consistency guard" yaklaşımı, üç farklı modelin çıktılarını entegre ederek, tek bir modelin yanlıgısının sistem seviyesinde hata üretmesini engellemektedir. Bu çok katmanlı doğrulama mekanizması, literatürdeki bu boşluğu doldurmaya yönelik özgün bir katkıdır.

İkinci olarak, üretim ortamında silent failure risklerinin yönetimi, özellikle hibrit sistemlerde, literatürde yeterince ele alınmamıştır. Feature schema lock, fingerprint

validation ve fail-fast startup davranışı gibi mekanizmaların sistematik entegrasyonu, gelecek çalışmalarda önceliklendirilmelidir [2]. Bu proje, üretim güvenilirliğini birincil tasarım gereksinimi olarak ele alarak bu boşluğa yanıt vermektedir.

Üçüncü olarak, XAI tekniklerinin klinik faydalılığı kontrollü kullanıcı çalışmalarıyla daha derinlemesine araştırılmalıdır. Bu proje, XAI'yi opsiyonel eklenti değil sistemin organik bileşeni olarak konumlandırıp artifact discovery mekanizmasını API sözleşmesine entegre ederek operasyonel kullanılabilirliği artırmaktadır.

Son olarak, MI lokalizasyonunda posterior MI gibi nadir tiplerin düşük temsili ve SCP kod eşleştirmesindeki belirsizlikler, gelecek araştırmalarda veri toplama stratejileri ve etiket kalitesi açısından ele alınmalıdır [3]. Bu proje, PMI'yı kapsam dışında bırakarak bu sınırlılığı açıkça dokümante etmekte ve gelecekte genişletilmesi gereken bir alan olarak işaretlemektedir. Özetle, bu çalışma klinik güvenilirlik, operasyonel dayanıklılık ve üretim güvenliği boyutlarında özgün katkılar sunarak EKG tabanlı AI sistemlerinin gerçek dünya uygulamalarına geçişinde karşılaşılan zorluklara bütüncül bir yaklaşım önermektedir.

3 MATERYAL VE YÖNTEM

Bu bölümde, CardioGuard-AI sisteminin geliştirilmesinde kullanılan veri seti, model mimarileri, hibrit yaklaşımlar, çoklu model orkestrasyonu, açıklanabilir yapay zeka bileşenleri ve üretim güvenilirliği mekanizmaları detaylı olarak açıklanmaktadır. Çalışmanın metodolojisi, yalnızca yüksek doğruluk oranına sahip bir model eğitmekle

sınırlı kalmayıp, aynı zamanda klinik ortamda güvenilir ve sürdürülebilir bir karar destek sistemi tasarlamayı hedeflemektedir. Bu kapsamda, veri setinin hazırlanması, etiket türetme süreçleri, model seçim gerekçeleri, orkestrasyona dayalı karar mekanizmaları ve fail-fast güvenlik doğrulamaları sistematik bir şekilde ele alınmaktadır.

3.1 VERİ SETİ: PTB-XL

3.1.1 VERİ SETİNİN ÖZELLİKLERİ

Çalışmada, PhysioNet platformu üzerinden açık erişimli olarak sunulan PTB-XL veri seti kullanılmıştır. PTB-XL, Wagner ve arkadaşları (2020) tarafından EKG sınıflandırma çalışmaları için standart bir benchmark olarak geliştirilmiş olup, 18,885 benzersiz hastadan toplanan 21,837 adet 10 saniyelik 12-derivasyonlu EKG kaydını içermektedir. Veri setindeki her kayıt, 100 Hz örnekleme frekansında kaydedilmiş olup, her derivasyon için 1,000 örnek noktası bulunmaktadır. Bu yapı, modellerin girdi tensör boyutunu $(12 \times 1,000)$ olarak standartlaştırmaktadır

Veri setinin en ayırt edici özelliklerinden biri, her kaydın iki bağımsız kardiyolog tarafından SCP-ECG (Standardized Communication Protocol for Computer Assisted Electrocardiography) standardına uygun şekilde etiketlenmiş olmasıdır. Toplam 71 farklı tanı ifadesi, likelihood skorları (0, 50, 100) ile birlikte çoklu-etiket formatında sunulmaktadır. Bu likelihood skorları, etiketin güvenilirlik derecesini ifade etmekte olup, bazı kayıtlarda düşük güvenilirli etiketler bulunabilmektedir. Çalışmada, minimum likelihood politikası 0.0 olarak belirlenmiş, yani tüm likelihood seviyelerindeki etiketler dahil edilmiştir. Veri setinin sinyal kalitesi açısından çeşitlilik göstermesi, gerçek klinik koşulları yansıtmaya kapasitesini artırmaktadır. Kayıtların yaklaşık %77'si yüksek kalite olarak işaretlenmiş olup, geri kalan kısımda baseline drift, elektriksel gürültü (50/60 Hz powerline interference) ve kas artefaktları gibi çeşitli bozulmalar bulunmaktadır.

3.1.2 VERİ BÖLÜNMESİ (SPLIT STRATEJİSİ)

PTB-XL veri seti, hasta bazlı stratified 10-fold cross-validation yapısı ile sunulmaktadır. Bu çalışmada, Wagner ve arkadaşları (2020) tarafından önerilen standart bölünme stratejisi benimsenmiştir: Fold 1-8 eğitim seti (17,469 kayıt), Fold 9 doğrulama seti (2,189 kayıt) ve Fold 10 test seti (2,179 kayıt) olarak ayrılmıştır. Bu

stratejinin kritik önemi, veri bölünmesinin hasta bazında yapılması ve böylece aynı hastanın farklı kayıtlarının hem eğitim hem de test setinde bulunmamasını garanti etmesidir. Hasta bazlı bölünme, data leakage (veri sızıntısı) riskini önleyerek, modelin gerçek genelleme kapasitesinin daha doğru bir şekilde ölçülmesini sağlamaktadır.

Sınıf dağılımının dengesiz olması (örneğin, NORM sınıfının diğer patolojilere kıyasla daha fazla örneğe sahip olması), model eğitiminde sınıf ağırlıklandırması (class weighting) stratejilerinin kullanılmasını gerekli kılmıştır. Eğitim aşamasında, BCEWithLogitsLoss fonksiyonu ile birlikte her sınıf için hesaplanan pozitif ağırlıklar (pos_weight) kullanılarak, azınlık sınıflarının öğrenilmesi teşvik edilmiştir.



Şekil 1. Veri seti filtreleme ve etiket kaynağı (data provenance): PTB-XL ham veriden MI seçimi ve lokalizasyon için geçerli alt kümenin oluşturulması.

Tablo 1. PTB-XL veri seti dağılımı (Train/Val/Test)

Split	Folds	Kayıt Sayısı	Toplama Oranı (%)
Train	1-8	17,469	80.00

Validation	9	2,189	10.02
Test	10	2,179	9.98
Toplam	-	21,837	100.00

3.1.3 ETİKET DÖNÜŞÜMLERİ VE TÜRETİLMİŞ ETİKET SİSTEMİ

PTB-XL'deki 71 SCP kodunun model eğitimi için doğrudan kullanımı, hem hesaplama karmaşıklığını artırmakta hem de bazı nadir kodların düşük temsili nedeniyle öğrenme zorluğu yaratmaktadır. Bu nedenle, veri setinin hiyerarşik etiket yapısından yararlanılarak, SCP kodları 5 ana superclass'a (NORM, MI, STTC, CD, HYP) ve 24 subclass'a eşlenmiştir. Bu eşleme, Wagner ve arkadaşları (2020) tarafından önerilen mapping tablosuna dayanmaktadır.

NORM Türetimi (Derived NORM): NORM sınıfı, diğer superclass'ların aksine, doğrudan bir SCP kodundan değil, türetilmiş bir kuralla elde edilmektedir. Bir EKG kaydının NORM olarak değerlendirilmesi, dört patoloji sınıfının (MI, STTC, CD, HYP) hiçbirinin belirli bir eşik değerin üzerinde olasılığa sahip olmaması durumunda gerçekleştirilmektedir. Matematiksel olarak, NORM skoru şu şekilde hesaplanmaktadır:

$$P_{\{NORM\}} = 1 - \max(P_{\{MI\}}, P_{\{STTC\}}, P_{\{CD\}}, P_{\{HYP\}})$$

Bu türetme yaklaşımının seçilmesinin temel gerekçesi, NORM'un bir hastalık kategorisi değil, patolojilerin yokluğunu temsil eden bir durum olmasıdır. Alternatif olarak, NORM'u beşinci bir sınıf olarak doğrudan eğitmek de mümkün olsa da, bu durumda patolojilerin kombinasyonları (örneğin, hem MI hem STTC) ile NORM arasındaki ayrımın net bir şekilde yapılması zorlaşmaktadır. Türetilmiş NORM yaklaşımı, sistemin mantıksal tutarlılığını artırmakta ve API yanıt sözleşmesinde (AIResult v1.0) açıkça dokümente edilmektedir.



Şekil 2. MI lokalizasyon etiket haritalama süreci ve mapping fingerprint: SCP kodlarından hedef lokalizasyon sınıf gruplarına dönüşüm.

3.1.4 VERİ ÖN İŞLEME

Veri ön işleme aşaması, model eğitimi öncesinde kritik bir role sahiptir. Z-score normalizasyonu, her derivasyon için ayrı ayrı uygulanarak, farklı derivasyonlardaki sinyal seviyesi farklılıklarını ortadan kaldırmaktadır. Girdi tensörlerinin şekli (batch, 12, 1000) şeklinde validasyonu, eğitim sırasında hata oluşmasını engeller. Ayrıca, eksik veya bozuk verilerin filtrelenmesi için QC (Quality Control) flag değerleri kontrol edilmektedir.


3.2 MODEL MİMARİSİ

3.2.1 ECGBACKBONE (CNN TEMEL MİMARİSİ)

ECGBackbone, kardiyak sinyallerdeki temporal desenleri öğrenmek için özel olarak tasarlanmış bir 1D CNN mimarisidir. Mimari giriş olarak 12-derivasyonlu EKG sinyalini (12×1000) alır ve işlemler sırasında Conv1d katmanları, BatchNormalization ve ReLU aktivasyonlarını sırayla uygular. Her Conv1d katmanı kernel boyutu 7 ile yapılandırılmış olup, aralarında Dropout(0.3) düzenleme mekanizması bulunmaktadır. Sonuçta, AdaptiveAvgPool1d katmanı aracılığıyla 64 boyutlu bir embedding vektörü elde edilmektedir.

Tasarım kararı olarak 1D-CNN seçilmesinin temel gerekçeleri şunlardır: Birincisi,

1D konvolüsyonlar, EKG sinyalindeki QRS kompleksi, ST segmenti ve T dalgası gibi karakteristik temporal özellikleri etkili bir şekilde öğrenmektedir. İkincisi, 2D-CNN'e kıyasla önemli ölçüde daha az parametre gerektirmektedir ve bu sayede daha hızlı eğitim ve çıkarım süresi sağlamaktadır. Üçüncüsü, transfer learning uygulamalarında kolaylık sağlamak ve önceden eğitilmiş ağ ağırlıklarından yararlanabilmektedir.



Şekil 3. ECGBackbone CNN mimarisi (katman analizi): Conv1D tabanlı bloklar ile gömlem (embedding) üretimi.

3.2.2 ÜÇ MODEL YAKLAŞIMI

CardioGuard-AI, üç ayrı nöral ağ modelinin özelleştirilmiş görevler için eğitilmesi ve ardından orkestrasyonlu bir şekilde entegre edilmesi prensibine dayanmaktadır. Bu multi-model yaklaşımı, sistemin güvenilirliğini ve açıklanabilirliğini artırmakta, ayrıca farklı klinik senaryolara uyum sağlamayı mümkün kılmaktadır.

Model 1: Superclass CNN (4-etiket sınıflandırıcı)

Bu model, beş temel superclass'tan dört tanesinin (MI, STTC, CD, HYP) olasılıklarını tahmin etmek üzere eğitilmiştir. Çıktı boyutu 4 olup, multi-label sınıflandırma için BCEWithLogitsLoss fonksiyonu ve sınıf ağırlıklandırması kullanılmıştır. Model kontrol noktası (checkpoint) `checkpoints/ecgcnn\_superclass.pt` olarak kaydedilmektedir.

Model 2: Binary MI CNN (1-etiket sınıflandırıcı)

Bu model, MI varlığının ikili (binary) tahminini gerçekleştirir. Çıktı boyutu 1 olup, sigmoid aktivasyonu ile [0, 1] aralığına normalleştirilir. Rol olarak, Superclass modeli ile uyum kontrolü (Consistency Guard) sağlayarak, farklı modellerin karar farklılıklarını tespit etmek ve gözden geçirme gereksinimi olan durumları işaretlemektedir. Checkpoint: `checkpoints/ecgcnn.pt`

Model 3: MI Lokalizasyon CNN (5-etiket sınıflandırıcı)

Bu model, MI'nin anatomik bölge tespitine odaklanmıştır. Çıktı boyutu 5 olup, multi-hot encoding ile AMI, ASMI, ALMI, IMI ve LMI bölgeleri sınıflandırılır. Eğitim süresinde, sadece MI lokalizasyon etiketleri bulunan örnekler kullanılır, bu da modelin sınıflandırma kapasitesini bu spesifik görevde odaklandırır. Checkpoint: `checkpoints/ecgcnn\_localization.pt`



Şekil 4. İnferans orkestrasyonu ve tutarlılık kapısı (Consistency Gate): Superclass CNN ve Binary Guard çıktıları üzerinden karar/triage akışı ve lokalizasyon modeline geçiş.

3.3 HİBRİT MİMARİ: CNN + XGBOOST ENSEMBLE

3.3.1 HİBRİT PIPELİNE MANTIĞI

CNN backbone'ı tarafından üretilen 64 boyutlu embedding vektörü, hibrit pipeline'ın başlangıcı olarak hizmet etmektedir. Bu embedding vektörü, StandardScaler kullanarak normalize edilir ve ardından dört ayrı XGBoost sınıflandırıcısına gönderilir (her superclass için bir tane). Her XGBoost modeli, ilgili sınıfın olasılığını tahmin eder. XGBoost çıktıları daha sonra Isotonic Calibration aracılığıyla kalibre edilir, böylece tahmin olasılıklarının gerçek olasılık değerlerine daha yakın hale gelmesi sağlanır. Son adımda, ensemble kombinasyonu şu şekilde hesaplanır: $P_{final} = \alpha \times P_{cnn} + (1-\alpha) \times P_{xgb}$, burada α kombinasyon ağırlığıdır.



Şekil 5. Hibrit çıkarım hattı ve özellik şeması kilidi (Schema Lock): CNN embedding → ölçekleme → XGBoost bankası → ensemble birleşimi.


3.3.2 XGBOOST HİPERPARAMETRELERİ

XGBoost modelleri, şu hiperparametre değerleri ile eğitilmektedir: $n_estimators$ (ağaç sayısı) 100 olarak ayarlanmış, her ağacın maksimum derinliği (max_depth) 5 ile sınırlandırılmıştır. Öğrenme oranı ($learning_rate$) 0.1 olup, her iterasyonda ağırlıklandırma katsayısı adım adım güncellenmektedir. Objective fonksiyonu olarak $binary:logistic$ seçilmiş ve sınıf dengesizliğini ele almak için $scale_pos_weight$ parametresi otomatik olarak hesaplanmıştır.

3.3.3 FEATURE SCHEMA LOCK (GÜVENLİK)

XGBoost modelleri, giriş özniteliklerinin boyut ve sırasına duyarlı olup, bu parametreler değişirse sessizce hata yapabilir. Bunu önlemek amacıyla, `feature_schema.json` dosyası adında bir güvenlik mekanizması uygulanmıştır. Bu dosya, beklenen öznitelik sayısını (64), öznitelik isimlerini (`cnn_feat_0`, `cnn_feat_1`, ..., `cnn_feat_63`) ve `schema`'nın `hash` değerini içermektedir. Runtime'da, CNN embedding'inin boyutu ve adı kontrol edilir, uyumsuzluk durumunda sistem fail-closed modu etkinleştirilmektedir.

3.4 İNFERANS ORKESTRASYONU



Şekil 6. Açıklanabilirlik (XAI) üretim iş akışı: Grad-CAM ve SHAP çıktılarının artefact deposuna kaydı ve AIResult ile ilişkilendirilmesi.

3.4.1 ÜÇ AŞAMALI KARAR AKIŞI

İnferans süreci, üç ardışık aşamada organize edilmiştir: İlk aşama Superclass ve Binary MI tahminlerini paralel olarak çalıştırır, ikinci aşama Consistency Guard mekanizması ile karar uyumunu kontrol eder, üçüncü aşama ise MI lokalizasyon modelini koşullu olarak tetikler.

Aşama 1: Superclass + Binary MI Tahmini

EKG sinyali, Superclass CNN ve Binary MI CNN'e eş zamanlı olarak gönderilir. Superclass modeli P_MI_super, P_STTC, P_CD, P_HYP olmak üzere dört çıktı sağlarken, Binary MI modeli P_MI_binary çıktısını üretir. Bu aşamada iki modelin çıktıları bağımsız olarak hesaplanmakta, henüz birleştirilmemektedir.


Aşama 2: Consistency Guard

Consistency Guard, iki modelin karar uyumunu kontrol etmektedir. AGREE_MI durumunda (her iki model de MI pozitif), triage seviyesi HIGH olarak ayarlanır ve sonuç doğrudan döndürülür. AGREE_NO_MI durumunda (her iki model de MI negatif), triage seviyesi LOW olarak ayarlanır. DISAGREE durumlarında (modellerden biri MI pozitif, diğeri negatif), triage seviyesi REVIEW olarak işaretlenir ve kaydın gözden geçirilmesi gerektiğine dair uyarı oluşturulur.

Aşama 3: MI Lokalizasyon Gate

MI Lokalizasyon Gate, lokalizasyon modelinin çalıştırılıp çalıştırılmayacağını karar verir. Strict mod'da, sadece AGREE_MI durumlarında lokalizasyon modeli tetiklenir. Recall-first mod'da ise, Superclass modelinin MI pozitif tahmin etmesi yeterlidir, bu da daha geniş kapsama izin verir (binary model uyarısı ile birlikte loglanır).

3.5 ÜRETİM GÜVENİLİRLİĞİ MEKANİZMALARI



Şekil 7. İstek yaşam döngüsü ve fail-fast kontrol sıralaması: Doğrulama, giriş ayrıştırma, schema lock ve fingerprint kontrolleri ile hata yönetimi.

3.5.1 FAIL-FAST CHECKPOINT VALIDATION

API servisi başlatılırken, tüm checkpoint dosyaları kapsamlı bir şekilde kontrol edilmektedir. Her checkpoint'ın çıktı boyutu (output_dim) doğrulanır: Superclass için 4, Binary MI için 1, Lokalizasyon için 5 olması gerekir. State-dict anahtar yöntemi kontrol edilir (Sequential vs Module mimarisi farklılıkları normalize edilir). Ayrıca, checkpoint'te saklanan eğitim parametreleri (learning rate, batch size vb.) kontrol edilir. Herhangi bir uyumsuzluk durumunda, API servisi başlatılmaz (fail-closed strateji).

3.5.2 MAPPING FINGERPRINT DOĞRULAMASI

MI lokalizasyon etiket mapping'i, projenin yaşam döngüsü boyunca değişebilir (örneğin, PMI dahil edilmesi, kod yeniden sınıflandırması vb.). Böyle bir değişiklik, üretim ortamındaki tahminlerin doğruluğunu olumsuz yönde etkileyebilir. Bu riski yönetmek için, mapping'in SHA256 hash'i kaydedilir. Runtime'da, mapping fingerprint'i beklenen değer ile karşılaştırılır, uyumsuzluk durumunda MappingDriftError oluşturulur ve sistem uyarı verilerek gözden geçirme yapılması istenir.

3.5.3 FEATURE SCHEMA LOCK

Feature schema lock mekanizması, XGBoost modellerinin giriş öznelik boyutunun (embedding boyutu = 64) veya sırasının değişmesini engellemektedir. Eğer CNN embedding boyutu bir neden ile değişirse (örneğin, farklı bir model versiyonu yüklenmesi), XGBoost modeli sessizce hata yapacak ve yanlış tahminler verebilecektir. Bu durumu önlemek amacıyla, beklenen öznelik sayısı, adları ve hash değeri feature_schema.json dosyasında saklanmakta ve her çıkarım sırasında doğrulanmaktadır.

3.6 API SÖZLEŞMESİ: AIRESULT V1.0

3.6.1 ENDPOINT TASARIMI

CardioGuard-AI API, dört ana endpoint sunmaktadır: GET /health servisi, API sunucusunun çalışıp çalışmadığını kontrol eder. GET /ready endpoint'i, tüm modellerin yüklü olup olup olmadığını doğrular ve sistem başlatma tamamlandıktan sonra bu endpoint true döner. POST /predict/superclass, Superclass tahminleri sağlar. POST /predict/mi-localization, MI lokalizasyon tahminlerini döner (Consistency Guard tarafından gated).



Şekil 8. Çok katmanlı sistem mimarisi: İstemci–API Gateway–FastAPI model servisi ve AIResult v1.0 çıktı sözleşmesi.

3.6.2 RESPONSE CONTRACT

Tüm tahmin yanıtları AIResult v1.0 sözleşmesine uygun olarak döndürülmektedir. Yanıt yapısı, identity bilgileri (case_id, request_id, timestamp), predictions (çok-etiketli patolojiler ve türetilmiş NORM), localization (MI alt türleri ve mapping_fingerprint), triage seviyesi (HIGH/REVIEW/LOW) ve kural açıklaması, tahmin kaynakları (CNN/XGB/Ensemble ayrımı), XAI artifactları (Grad-CAM, SHAP görselleri) ve sürüm bilgileri (checkpoint version, contract version) içermektedir. Bu yapı, klinik karar destek ve audit trail (denetim izi) oluşturmayı mümkün kılmaktadır.

3.6.3 DEĞERLENDİRME METRİKLERİ (PLANLANAN)

Model performansının değerlendirilmesinde, çoklu-etiketli sınıflandırma görevlerine uygun metrikler kullanılacaktır: Precision, Recall ve F1-score, hem etiket bazında hem de macro-average olarak hesaplanacaktır. ROC eğrisi altındaki alan (AUROC), sınıf ayrımcılığı yeteneğini ölçmektedir. Confusion matrix, özellikle MI sınıflandırması için ayrıntılı analiz sağlayacaktır. Consistency rate, Binary ve Superclass modellerinin karar uyum oranını gösterecektir. XAI sanity checks, randomization testleri aracılığıyla açıklanabilirlik çıktılarının gerçekçiliğini doğrulayacaktır.

4 SONUÇLAR

Gereksinim Listesi

Bu bölümde CardioGuard-AI karar destek sistemi için tanımlanan işlevsel, teknik ve güvenlik gereksinimleri özetlenmektedir. Gereksinimler, sistemin EKG tabanlı MI tespiti, lokalizasyonu, açıklanabilirlik ve üretim ortamı güvenilirliği hedeflerini karşılayacak şekilde yapılandırılmıştır.

Fonksiyonel gereksinimler

A : Veri Yükleme ve İşleme Gereksinimleri

Sistemin PTB-XL veri setinden EKG sinyallerini yüklemesi, işlemesi ve normalize etmesi için gerekli fonksiyonları tanımlar. Bu gereksinimler, 12 derivasyonlu EKG sinyallerinin WFDB formatında okunması, 1000 örnek $\times$ 12 kanal boyutunda işlenmesi ve MinMax normalizasyonu ile 0-1 aralığına ölçeklenmesini kapsar.

Tablo 2 Veri Yükleme ve İşlem Gereksinimleri

ID	Gereksinim	Açıklama	Öncelik	Durum
FR-01	PTB-XL Veri Yükleme	Sistem, PTB-XL veri setinden EKG sinyallerini yükleyebilmelidir. WFDB formatı desteklenmelidir.	Yüksek	Tamamlandı
FR-02	12 Derivasyon Sinyal İşleme	Sistem, 12 derivasyonlu EKG sinyallerini işleyebilmelidir. Sinyal boyutu: 1000 örnek $\times$ 12 kanal, örnekleme frekansı: 100 Hz.	Yüksek	Tamamlandı
FR-03	Sinyal Normalizasyonu	Sistem, MinMax normalizasyonu ile her derivasyon için 0-1 aralığında ölçekleme yapabilmelidir.	Yüksek	Tamamlandı

B : Sınıflandırma ve Tahmin Gereksinimleri

Sistemin patoloji tespiti, mı lokalizasyonu, model tutarlılık kontrolü ve triaj seviyesi belirleme yeteneklerini tanımlar. Bu gereksinimler, dört patoloji sınıfının çoklu etiket olarak tespitini, mı durumunda beş anatomik bölgenin lokalize edilmesini, binary ve superclass modelleri arasında tutarlılık kontrolü yapılmasını ve sonuçlara göre uygun triaj seviyesinin atanmasını sağlar.

Tablo 3 Sınıflandırma ve Tahmin Gereksinimleri

ID	Gereksinim	Açıklama	Öncelik	Durum
FR-04	Patoloji Sınıflandırması	Sistem, dört patoloji sınıfını (MI, STTC, CD, HYP) çoklu etiket olarak tespit edebilmelidir. Her sınıf için olasılık skoru ve karar çıktısı üretilmelidir.	Yüksek	Tamamlandı
FR-05	MI Lokalizasyonu	Sistem, MI tespit edildiğinde beş anatomik bölgeyi (AMI, ASMI, ALMI, IMI, LMI) lokalize edebilmelidir. Çoklu bölge tespiti desteklenmelidir.	Yüksek	Tamamlandı
FR-06	Tutarlılık Kontrolü	Sistem, Binary MI ve Superclass MI modelleri arasında tutarlılık kontrolü yapabilmelidir. Uyumsuzluk durumunda inceleme triajı atanmalıdır.	Yüksek	Tamamlandı
FR-10	Triaj Seviyeleri	Sistem, tahmin sonuçlarına göre triaj seviyesi (Yüksek, Orta, Düşük, İnceleme) belirleyebilmelidir.	Yüksek	Tamamlandı

C : Hibrit Model Pipeline Gereksinimleri

Sistemin CNN ve XGBoost modellerini birleştirerek hibrit tahmin pipeline'ı oluşturmasını tanımlar. Bu gereksinimler, NORM skorunun diğer patoloji olasılıklarından türetilmesini ve CNN ile XGBoost çıktılarının ağırlıklı ortalama ile ensemble edilmesini kapsar.

Tablo 4 Hibrit Model Pipeline Gereksinimleri

ID	Gereksinim	Açıklama	Öncelik	Durum
FR-11	NORM Türetme	Sistem, NORM skorunu " $1 - \max(P_MI, P_STTC, P_CD, P_HYP)$ " formülü ile türetebilmelidir. NORM bir sınıflandırıcı çıktısı değildir, diğer olasılıklardan türetilir.	Orta	Tamamlandı
FR-12	Ensemble Kombinasyonu	Sistem, CNN ve XGBoost olasılıklarını ağırlıklı ortalama ile birleştirebilmelidir. Varsayılan ağırlık değeri: $\alpha = 0.15$.	Orta	Tamamlandı

D : Açıklanabilirlik (XAI) Gereksinimleri

Sistemin tahmin sonuçlarını açıklanabilir kılmak için görselleştirme ve önem skoru üretme yeteneklerini tanımlar. Bu gereksinimler, CNN modelleri için Grad-CAM ile zamansal açıklama haritalarının ve XGBoost modelleri için SHAP ile özellik önem skorlarının üretilmesini sağlar.

Tablo 5 Açıklanabilirlik (XAI) Gereksinimleri

ID	Gereksinim	Açıklama	Öncelik	Durum
FR-07	Grad-CAM Açıklamaları	Sistem, CNN modeli için Grad-CAM ile zamansal açıklama haritaları üretebilmelidir. SmoothGrad-CAM desteği sağlanmalıdır.	Orta	Tamamlandı
FR-08	SHAP Açıklamaları	Sistem, XGBoost modelleri için SHAP TreeExplainer ile özellik önem skorları üretebilmelidir.	Orta	Tamamlandı

E : API Servisi Gereksinimleri

Sistemin FastAPI framework üzerinden REST API servisi sunma yeteneğini tanımlar. Bu gereksinim, superclass tahmin, MI lokalizasyonu ve sistem sağlık kontrolü endpoint'lerinin sağlanmasını kapsar.

Tablo 6 API Servisi Gereksinimleri

ID	Gereksinim	Açıklama	Öncelik	Durum
FR-09	REST API	Sistem, FastAPI framework üzerinden tahmin servisi sunabilmelidir. Desteklenen uç noktalar: /predict/superclass, /predict/mi-localization, /health	Yüksek	Tamamlandı

Fonksiyonel Olmayan Gereksinimler

A : güvenilirlik ve güvenlik gereksinimleri

Sistemin üretim ortamında güvenilir çalışması ve veri bütünlüğü sağlaması için gerekli kontrolleri tanımlar. Bu gereksinimler, hatalı model checkpoint'leri ile sistemin başlamamasını sağlayan fail-fast mekanizmasını, api çıktılarının airesult v1.0 kontratına tam uyumunu ve mi lokalizasyon eşleme parmak izi kontrolünü kapsar.

Tablo 7 Güvenilirlik ve Güvenlik Gereksinimleri

ID	Gereksinim	Açıklama	Öncelik	Metrik
NFR-01	Hızlı Başarısızlık (Fail-Fast)	Kontrol noktası doğrulaması başlangıçta yapılmalı, hatalı kontrol noktası varsa sistem başlamamalıdır.	Yüksek	Başlangıç süresi < 5 saniye
NFR-05	Kontrat Uyumu	Tüm API çıktıları AIResult v1.0 kontratına uygun olmalıdır.	Yüksek	%100 uyum
NFR-06	Eşleme Parmak İzi	MI lokalizasyon eşleme parmak izi değişikliğinde sistem uyarı vermeli ve başlamamalıdır.	Yüksek	Parmak izi: 8ab274e06afa1be8


B : Performans Gereksinimleri

Sistemin performans hedeflerini ve kaynak kullanım sınırlarını tanımlar. Bu gereksinimler, api yanıt süresinin 500 milisaniye altında tutulmasını, toplam model boyutunun optimize edilmesini ve sistemin gpu olmadan sadece cpu üzerinde çalışabilmesini sağlar.

Tablo 8 Performans Gereksinimleri

ID	Gereksinim	Açıklama	Öncelik	Metrik
NFR-02	API Yanıt Süresi	Tek tahmin için API yanıt süresi kabul edilebilir olmalıdır.	Orta	< 500 ms (CPU)
NFR-03	Model Boyutu	Toplam kontrol noktası boyutu optimize edilmelidir.	Düşük	< 2 MB
NFR-04	CPU Desteği	Sistem, GPU olmadan sadece CPU üzerinde çalışabilmelidir.	Yüksek	PyTorch CPU backend

C : GEREKSİNİM BAĞIMLILIKLARI



Şekil 9 Gereksinim Bağımlılıkları

Use case diyagramları

CardioGuard-AI sistemi, EKG tabanlı patoloji tespiti için 3 ana aktör ve 9 kullanım senaryosu ile tasarlanmıştır. Sistem, klinisyenlerin EKG sinyallerini yüklemesinden başlayarak, patoloji tespiti, MI lokalizasyonu, triaj belirleme ve açıklanabilir yapay zeka (XAI) raporları sunmaya kadar kapsamlı bir iş akışı sağlamaktadır.

Geliştirme Kullanım Senaryoları:

- Model Eğitimi: ML Mühendisi tarafından yürütülen model geliştirme. Yeni modeller eğitilir, hiperparametreler optimize edilir ve checkpoint'ler oluşturulur.

Operasyon Kullanım Senaryoları:

- Checkpoint Yönetimi: ML Mühendisi ve Sistem Yöneticisi tarafından yürütülen model versiyonlama. Model ağırlıkları doğrulanır, güncellenir ve geriye alınır.
- Sağlık Kontrolü: Sistem Yöneticisi tarafından yürütülen sistem izleme. GET /health ve GET /ready endpoint'leri kullanılarak sistem durumu kontrol edilir.

9 Ana Kullanım Senaryosu:

- Sistemin kullanım senaryoları üç kategoride organize edilmiştir:

Klinik Kullanım Senaryoları:

- EKG Sinyali Yükleme: Klinisyen tarafından tetiklenen temel girdi işlemi. EKG dosyasının formatı, boyutu ve değerleri kontrol edilerek sisteme yüklenir.
- Patoloji Tespiti: Sistem tarafından otomatik olarak tetiklenen çok sınıflı sınıflandırma. MI, STTC, CD ve HYP olmak üzere dört patoloji sınıfı için olasılık skorları hesaplanır.
- MI Lokalizasyonu: Sistem tarafından koşullu olarak tetiklenen anatomik lokalizasyon. MI tespit edilmişse, beş bölge (AMI, ASMI, ALMI, IMI, LMI) için tahminler üretilir.
- Sonuç Raporlama: Klinisyen tarafından istenen rapor üretimi. Tüm tahminler AIResult v1.0 formatında JSON olarak döndürülür.
- XAI Görüntüleme: Klinisyen tarafından istenen açıklanabilirlik görüntüleri. Grad-CAM ısı haritaları ve SHAP önem skorları sunulur.
- Triaj Belirleme: Sistem tarafından otomatik olarak tetiklenen öncelik belirlemesi. Tahmin sonuçlarına göre HIGH, MEDIUM, LOW veya REVIEW seviyeleri atanır.

Geliştirme Kullanım Senaryoları:

- Model Eğitimi: ML Mühendisi tarafından yürütülen model geliştirme. Yeni modeller eğitilir, hiperparametreler optimize edilir ve checkpoint'ler oluşturulur.

Operasyon Kullanım Senaryoları:

- Checkpoint Yönetimi: ML Mühendisi ve Sistem Yöneticisi tarafından yürütülen model versiyonlama. Model ağırlıkları doğrulanır, güncellenir ve geriye alınır.
- Sağlık Kontrolü: Sistem Yöneticisi tarafından yürütülen sistem izleme. GET /health ve GET /ready endpoint'leri kullanılarak sistem durumu kontrol edilir.


Aktör Kullanım Senaryoları:

CardioGuard-AI sisteminin üç ana aktörü ve özellikleri aşağıda detaylı olarak açıklanmıştır:

Klinisyen (Birincil Aktör): Hastane ortamında çalışan doktor veya kardiyolog. EKG sinyallerini sisteme yükler, tahmin sonuçlarını yorumlar ve hasta bakım kararları alır. Sistem arayüzü web tabanlıdır ve REST API üzerinden tahmin istekleri gönderir. EKG Sinyali Yükleme, Sonuç Raporlama ve XAI Görüntüleme senaryolarında aktif rol alır.

ML Mühendisi (Birincil Aktör): Makine öğrenimi uzmanı olarak görev yapar. PyTorch ve XGBoost modellerini eğitir, hiperparametreleri optimize eder, model performansını değerlendirir. Python training scriptleri ve Jupyter notebook'lar kullanır. Model Eğitimi ve Checkpoint Yönetimi senaryolarında sorumludur.

Sistem Yöneticisi (Birincil Aktör): BT operasyon personeli olarak görev yapar. FastAPI sunucusu, model yükleme durumu, database bağlantıları ve sistem sağlığını izler. Monitoring tool'ları (Prometheus, Grafana) kullanır. Checkpoint Yönetimi ve Sağlık Kontrolü senaryolarında görev alır.



Şekil 10. Kullanım Senaryoları Diyagramı

Class Diyagramı

Bu bölümde CardioGuard-AI karar destek sisteminin yazılım mimarisi ve sınıf yapısı detaylı olarak açıklanmaktadır. Sistem, modüler bir yapıda yedi ana paketten oluşmaktadır ve SOLID tasarım prensipleri doğrultusunda geliştirilmiştir.

GENEL BAKIŞ

CardioGuard-AI sistemi, her biri belirli bir sorumluluğa sahip yedi ana paketten oluşan katmanlı bir mimari ile tasarlanmıştır. Bu paketler arasında net bağımlılık ilişkileri tanımlanmış ve gevşek bağıllık (loose coupling) prensibi uygulanmıştır.

Model Paketi (src.models): Yapay zeka modellerinin tanımlandığı pakettir. ECG sinyallerini işleyen evrimsel sinir ağları (CNN) ve bunların farklı varyantları burada yer alır. Superclass, Binary MI ve Lokalizasyon modelleri için gerekli sınıf yapıları içerir.

Veri Paketi (src.data): Veri yükleme, işleme ve etiketleme işlemlerinden sorumludur. PTB-XL veri setinin yüklenmesi, EKG sinyallerinin normalizasyonu ve patoloji etiketlerinin üretilmesi bu pakette gerçekleştirilir.

Pipeline Paketi (src.pipeline): Tahmin ve eğitim iş akışlarını yöneten pakettir. Çıkarım (inference) pipeline'ı, tutarlılık kontrol mekanizması (Consistency Guard) ve model eğitim sınıfları burada bulunur.

XAI Paketi (src.xai): Açıklanabilir yapay zeka bileşenlerini içerir. Grad-CAM ısı haritaları, SHAP önem skorları ve XAI sanity check mekanizmaları bu pakette tanımlanmıştır.


Kontrat Paketi (src.contracts): API response şemalarını ve veri dönüşüm mekanizmalarını içerir. AIResult v1.0 formatına uygun veri yapılarının oluşturulması burada gerçekleşir.

Backend Paketi (src.backend): FastAPI web servisi ve REST API endpoint'lerinin tanımlandığı pakettir. HTTP isteklerinin işlenmesi, response formatlarının oluşturulması ve uygulama durumu yönetimi burada yapılır.

Yardımcı Paket (src.utils): Checkpoint doğrulama, güvenli model yükleme ve performans metriklerinin hesaplanması gibi yardımcı işlevler içerir.

Paketler Arası İlişkiler:

Backend Paketi, sistem giriş noktası olarak Model, Pipeline ve Kontrat paketlerini kullanır. Pipeline Paketi, Model ve Veri paketlerine bağımlıdır ve tahmin iş akışını yönetir. XAI Paketi, Model paketini kullanarak açıklama üretir. Kontrat Paketi, Veri paketinden faydalananarak response yapılarını oluşturur. Tüm paketler gerektiğinde Yardımcı Paketten destek alır.



Şekil 11. Paket Bağımlılıkları

Model Paketi

Model paketi, yapay zeka modellerinin temel yapı taşlarını içerir. PyTorch nn.Module sınıfından türetilen model bileşenleri modüler ve yeniden kullanılabilir şekilde tasarlanmıştır.

Yapılandırma Sınıfı

ECGCNNConfig: Model yapılandırma parametrelerini tutan veri sınıfıdır. Giriş kanal sayısı (varsayılan 12, 12-derivasyonlu EKG için), filtre sayısı (varsayılan 64), kernel boyutu (varsayılan 7), dropout oranı (varsayılan 0.3) ve lokalizasyon çıktı boyutu (varsayılan 2) parametrelerini içerir. Bu sınıf, model başlatma sırasında kullanılır ve hiperparametr yönetimini kolaylaştırır.

Omurga Sınıfı

ECGBackbone: Tüm model varyantlarının paylaştığı evrişimsel sinir ağı omurgasıdır. Giriş olarak 12×1000 boyutunda EKG sinyali alır ve 256 boyutlu gömme (embedding) vektörü üretir. ECGCNNConfig nesnesini kullanarak başlatılır. forward metodu ile ileri geçiş (forward pass) gerçekleştirilir. Evrişimsel katmanlar, aktivasyon fonksiyonları ve dropout katmanlarından oluşan Sequential yapı içerir.

Kafa Sınıfları

BinaryHead: İkili sınıflandırma için tasarlanmış kafa sınıfıdır. 256 boyutlu gömme vektörünü alır ve tek çıktılı doğrusal katman uygular. Binary MI modelinde kullanılır ve MI/Normal ayrımı yapar. Sigmoid aktivasyonu ile 0-1 aralığında olasılık skoru üretir.

MultiClassHead: Çoklu sınıf sınıflandırma için genel amaçlı kafa sınıfıdır. Giriş özellik boyutu ve sınıf sayısı parametreleriyle başlatılır. n çıktılı doğrusal katman içerir. Sigmoid aktivasyonu ile her sınıf için bağımsız olasılık skoru hesaplar.

FiveClassHead: Beş sınıflı MI lokalizasyon tespiti için özelleştirilmiş kafa sınıfıdır. MultiClassHead sınıfından türetilir ve sınıf sayısı parametresi 5 olarak sabitlenmiştir. AMI, ASMI, ALMI, IMI ve LMI bölgeleri için tahmin üretir.

LocalizationHead: Regresyon çıktısı için tasarlanmış kafa sınıfıdır. Giriş özellik boyutu ve çıktı boyutu parametreleriyle başlatılır. Doğrusal katman içerir ve aktivasyon fonksiyonu kullanmaz. Lokalizasyon koordinatları veya sürekli değerler üretmek için kullanılabilir.

Tam Model Sınıfları

ECGCNN: Tek görev EKG sınıflandırma modelidir. ECGBackbone ve bir kafa sınıfı (BinaryHead veya MultiClassHead) içerir. ECGCNNConfig ve sınıf sayısı parametreleriyle başlatılır. forward metodu ile girdi sinyali önce omurgadan geçirilir, ardından kafa sınıfı uygulanır. Binary MI ve Superclass modelleri için bu sınıf kullanılır.


MultiTaskECGCNN: Çoklu görev modeli olup hem sınıflandırma hem lokalizasyon yapar. ECGBackbone, bir ana kafa sınıfı ve LocalizationHead içerir. forward metodu ile sınıflandırma ve lokalizasyon çıktıları aynı anda üretilir. Dictionary formatında sonuç döner: classification ve localization anahtarları ile.

Model Varyantları:

Binary MI Modeli: Bir çıktı üretir. BinaryHead kullanır. MI ve Normal sınıflarını ayırt eder. Consistency Guard mekanizmasında kullanılır.

Superclass Modeli: Dört çıktı üretir. MultiClassHead kullanır. MI, STTC, CD ve HYP patolojilerini tespit eder. Çoklu etiket sınıflandırma yapar.

Lokalizasyon Modeli: Beş çıktı üretir. FiveClassHead kullanır. AMI, ASMI, ALMI, IMI ve LMI bölgelerini lokalize eder. MI tespit edildiğinde koşullu olarak çalışır.



Şekil 12. Model Paketi Class Diyyagramı

Veri Paketi

Veri paketi, EKG sinyallerinin yüklenmesi, işlenmesi ve etiketlenmesi süreçlerini yönetir. PyTorch Dataset arayüzüne uygun sınıflar içerir.

Dataset Sınıfları

SignalDataset: Genel amaçlı EKG sinyal dataset sınıfıdır. Pandas DataFrame, dosya yolu, dosya adı sütunu, etiket sütunu ve transform fonksiyonu parametreleriyle başlatılır. Önbellekleme (caching) desteği içerir. `__len__` metodu ile dataset boyutu döner. `__getitem__` metodu ile indeks numarasına göre sinyal ve etiket tuple'ı döner. `__iter__` metodu ile dataset üzerinde iterasyon yapılabilir.

CachedSignalDataset: Bellekte önbelleğe alınmış dataset sınıfıdır. NumPy array formatında sinyal ve etiketler içerir. SignalDataset'e göre daha hızlıdır çünkü diskten okuma yapmaz. Transform fonksiyonu ile anlık dönüşümler desteklenir. Eğitim sırasında hız açısından avantaj sağlar.

Yapılandırma Sınıfı

PTBXLConfig: PTB-XL veri seti konfigürasyon parametrelerini içerir. Veri dizini (`data_dir`), metadata dosya adı, SCP statements dosya adı, örnekleme frekansı (varsayılan 100 Hz), sinyal uzunluğu (varsayılan 1000 örnek) ve derivasyon sayısı (varsayılan 12) parametreleri tanımlanır.

İşleme Sınıfları

LabelProcessor: Patoloji etiketlerinin üretilmesinden sorumludur. `add_binary_mi_labels` metodu ile DataFrame'e MI/Normal etiketleri eklenir. `add_superclass_labels` metodu ile dört sınıf etiketi eklenir. `add_5class_labels` metodu ile beş bölge etiketi eklenir. `extract_codes_above_threshold` metodu ile belirli bir eşiğin üzerindeki SCP kodlarını çıkarır. Minimum olasılık parametresi ile güvenlik eşiği uygulanır.


MILocalizationProcessor: LabelProcessor'ı genişleten özel sınıftır. MI lokalizasyon etiketlerinin üretilmesinden sorumludur. MI_LOCALIZATION_REGIONS listesi ile beş bölge tanımlanır (AMI, ASMI, ALMI, IMI, LMI). MI_CODE_TO_REGIONS dictionary ile SCP kodlarının bölgelere eşlenmesi yapılır. EXCLUDED_MI_CODES listesi ile hariç tutulacak kodlar belirtilir. extract_mi_regions metodu ile SCP kodlarından bölgeler çıkarılır. get_mi_localization_mask metodu ile MI tespiti yapılan kayıtlar için mask oluşturur.

SignalLoader: EKG sinyallerinin yüklenmesinden sorumludur. load_single_signal metodu ile tek sinyal yüklenir. load_signals_batch metodu ile toplu sinyal yükleme yapılır. build_npz_cache metodu ile NPZ formatında ön bellek oluşturur. load_npz_cache metodu ile ön bellekten sinyal ve etiketler yüklenir. WFDB formatı desteklenir.

Normalizer: Sinyal normalizasyon işlemlerini içerir. min_max_normalize metodu ile 0-1 aralığına ölçekleme yapar. z_score_normalize metodu ile standartlaştırma uygular. per_lead_normalize metodu ile derivasyon bazında normalizasyon yapar.

Veri Akışı:

Ham PTB-XL veritabanından (21,837 kayıt) SignalLoader ile sinyaller yüklenir. Metadata DataFrame oluşturulur. LabelProcessor ile patoloji etiketleri üretilir. MIMLocalizationProcessor ile MI lokalizasyon etiketleri eklenir. Normalizer ile sinyaller normalize edilir. SignalDataset veya CachedSignalDataset oluşturulur. PyTorch DataLoader ile model eğitimi için batch'ler üretilir.



Şekil 13. Veri Paketi Class Diyagramı

Pipeline paketi

Pipeline paketi, tahmin ve eğitim iş akışlarını yöneten sınıfları içerir. Consistency Guard mekanizması ve model eğitim sınıfları burada tanımlanmıştır.

Uyum Kontrol Sınıfları

AgreementType: Enum sınıfıdır ve dört uyum tipi tanımlar. AGREE_MI: Her iki model de MI tespit etmiştir. AGREE_NO_MI: Her iki model de MI tespit etmemiştir. **DISAGREE_TYPE_1:** Superclass MI tespit etmiş, Binary MI tespit etmemiştir. **DISAGREE_TYPE_2:** Binary MI tespit etmiş, Superclass MI tespit etmemiştir.

ConsistencyResult: Tutarlılık kontrol sonucunu tutan veri sınıfıdır. Superclass MI olasılığı, Binary MI olasılığı, Superclass MI kararı (boolean), Binary MI kararı (boolean), AgreementType değeri, triaj seviyesi (HIGH/MEDIUM/LOW/REVIEW), uyarı listesi içerir. to_dict metodu ile dictionary formatına dönüştürülür.

ConsistencyGuard: Model uyum kontrol mekanizmasıdır. check_consistency metodu ile iki model çıktısı karşılaştırılır. Eşik değerleri parametresi ile karar sınırları belirlenir. ConsistencyResult nesnesi döndürülür. should_run_localization metodu ile lokalizasyon yapılıp yapılmayacağına karar verilir. Gate mode parametresi ile lokalizasyon tetikleme stratejisi belirlenir. derive_norm_from_superclass metodu ile NORM skorunun türetilmesi yapılır.


Uyum Tipi Açıklamaları:

AGREE_MI durumunda: Superclass MI pozitif, Binary MI pozitif. Triaj seviyesi Yüksek atanır. Her iki model de MI tespit etmiştir, güvenilir sonuç.

AGREE_NO_MI durumunda: Superclass MI negatif, Binary MI negatif. Triaj seviyesi Düşük atanır. Her iki model de MI tespit etmemiştir, güvenilir sonuç.

DISAGREE_TYPE_1 durumunda: Superclass MI pozitif, Binary MI negatif. Triaj seviyesi İnceleme atanır. Düşük güvenilirlikli MI tespiti, manuel inceleme gerekli.

DISAGREE_TYPE_2 durumunda: Superclass MI negatif, Binary MI pozitif. Triaj seviyesi İnceleme atanır. Superclass modeli MI'yı kaçırmış olabilir, manuel inceleme gerekli.



Şekil 14. Pipeline Paketi Class Diyagramı

XAI Paketi

XAI paketi, açıklanabilir yapay zeka bileşenlerini içerir. Grad-CAM, SHAP ve sanity check mekanizmaları bu pakette tanımlanmıştır.

Açıklama Üretici Sınıfları

GradCAM: Gradient-weighted Class Activation Mapping uygulayan sınıftır. Model ve hedef katman parametreleriyle başlatılır. generate metodu ile girdi ve sınıf indeksi parametreleriyle ısı haritası üretir. Gradyan ve aktivasyon değerleri Hook mekanizması ile yakalanır. NumPy array formatında ısı haritası döndürür. 12 derivasyon için zamansal ısı haritası üretir.

SHAPExplainer: Soyut (abstract) temel sınıftır. explain metodu tanımlanmıştır ancak implement edilmemiştir. Farklı SHAP açıklayıcı türleri bu sınıftan türetilir.

SHAPXGBExplainer: SHAPExplainer'dan türetilir. XGBoost modelleri için SHAP TreeExplainer kullanır. Model parametresiyle başlatılır. explain_single metodu ile tek örnek için önem skorları üretir. explain_batch metodu ile toplu açıklama yapılır. get_feature_importance metodu ile genel özellik önem sıralaması döndürür.

SHAPOVREExplainer: SHAPExplainer'dan türetilir. One-vs-Rest XGBoost modelleri için açıklama üretir. Model dictionary parametresiyle başlatılır. explain_per_class metodu ile her sınıf için ayrı SHAP değerleri hesaplar. Dictionary formatında sınıf bazlı açıklamalar döner.

Doğrulama ve Görselleştirme Sınıfları


SanityChecker: XAI açıklamalarının güvenilirliğini test eder. randomize_model_weights metodu ile model ağırlıkları rastgele yapılır. compare_explanations metodu ile orijinal ve rastgeleştirilmiş açıklamalar karşılaştırılır. run_sanity_check metodu ile tam test süreci çalıştırılır ve boolean sonuç döner. P değeri 0.001 eşiği kullanılır.

XAIVisualizer: Açıklama görselleştirmelerini üretir. `plot_gradcam_overlay` metodu ile sinyal üzerine ısı haritası bindirimi yapar. `plot_shap_summary` metodu ile SHAP önem grafiği oluşturur. Matplotlib Figure nesneleri döndürür. `save_artifacts` metodu ile görselleri PNG formatında kaydeder.

XAIReporter: Metin tabanlı açıklama raporları üretir. `generate_narrative` metodu ile tahmin ve açıklamalardan klinik açıklama metni oluşturur. `create_report` metodu ile Markdown formatında rapor üretir. Çalıştırma dizini parametresiyle raporun kaydedileceği yol belirlenir.

Açıklama Akışı:

EKG sinyali ve tahminler girdi olarak alınır. GradCAM sınıfı ile zamansal ısı haritaları üretilir. SHAP açıklayıcı sınıfları ile önem skorları hesaplanır. SanityChecker ile açıklamaların güvenilirliği doğrulanır. XAIVisualizer ile PNG formatında görselleştirmeler oluşturulur. XAIReporter ile Markdown formatında metin açıklamaları üretilir. Tüm artifactlar `AIResult v1.0` response'una eklenir.



Şekil 15. XAI Paketi Class Diyagramı

Açıklama Yöntemleri

Tablo 9 Kullanılan XAI Yöntemleri

Yöntem	Model	Çıktı	Görselleştirme
Grad-CAM	CNN	Isı haritası	Sinyal üzeri overlay
SHAP	XGBoost	Özellik önemi	Çubuk grafik

Backend paketi

Backend paketi, FastAPI web servisi ve REST API endpoint'lerinin tanımlandığı pakettir. HTTP isteklerinin işlenmesi ve response formatlarının oluşturulması burada yapılır.

Uygulama Sınıfları

FastAPIApp: Ana uygulama sınıfıdır. Title ve version özellikleri içerir. CORS middleware ile çapraz kaynak istekleri desteklenir. Uygulama başlatma ve kapatma olayları tanımlanmıştır.

AppState: Global uygulama durumu sınıfıdır. Superclass modeli, Binary modeli, Lokalizasyon modeli, XGBoost modelleri dictionary, kalibratörler dictionary, StandardScaler, eşik değerleri dictionary ve yüklenme durumu (is_loaded boolean) içerir. load_models metodu ile checkpoint yolları, XGBoost dizini ve eşik değerleri yolu parametreleriyle tüm modeller yüklenir. Singleton pattern uygulanmıştır.

Response Sınıfları

PredictionProbabilities: Patoloji olasılık skorlarını içerir. MI float, STTC float, CD float, HYP float, NORM float özellikleri vardır. 0-1 aralığında değerler alır.

PrimaryPrediction: Birincil tahmin bilgilerini içerir. Label string (tespit edilen patoloji), confidence float (güven skoru), rule string (karar kuralı açıklaması) özellikleri vardır.

SourceProbabilities: Tahmin kaynaklarını ayırt eder. CNN dictionary, XGB dictionary, Ensemble dictionary içerir. Her dictionary MI, STTC, CD, HYP olasılıklarını içerir.

VersionInfo: Versiyon bilgilerini içerir. Model hash string (checkpoint parmak izi), threshold hash string (eşik değerleri parmak izi), API version string, timestamp string özellikleri vardır.

SuperclassPredictionResponse: Superclass tahmin endpoint'i response'udur. Mode string, probabilities (PredictionProbabilities nesnesi), predicted_labels listesi, thresholds dictionary, primary (PrimaryPrediction nesnesi), sources (SourceProbabilities nesnesi), versions (VersionInfo nesnesi) içerir.

MILocalizationResponse: MI lokalizasyon endpoint'i response'udur. MI detected boolean, region probabilities dictionary, detected regions listesi, label space string, mapping fingerprint string, localization head type string içerir.

HealthResponse: Health check endpoint'i response'udur. Status string (ok/unavailable) ve timestamp string içerir.

ReadyResponse: Readiness check endpoint'i response'udur. Ready boolean, models loaded dictionary (her model için boolean), message string içerir.


API Endpoint'leri

POST /predict/superclass: EKG sinyali alır ve SuperclassPredictionResponse döndürür. Çoklu etiket patoloji tahmini yapar. Multipart form data ile dosya yükleme desteklenir.

POST /predict/mi-localization: EKG sinyali alır ve MIModalizationResponse döndürür. MI anatomik lokalizasyonu yapar. Koşullu olarak çalışır (MI tespit edilmişse).

GET /health: HealthResponse döndürür. API sunucusunun canlı olup olmadığını kontrol eder. Kubernetes liveness probe için kullanılır.

GET /ready: ReadyResponse döndürür. Tüm modellerin yüklenip yüklenmediğini kontrol eder. Kubernetes readiness probe için kullanılır.



Şekil 16. Backend Paketi Class Diyagramı

Planlanan sınıflar

CardioGuard-AI sistemi sürümü için dört yeni sınıf planlanmıştır. Bu sınıflar, sistemin açıklanabilirlik, güvenilirlik ve otomatik raporlama kapasitesini artırmayı hedeflemektedir.

RAG Entegrasyonu

RAGRetriever: Retrieval-Augmented Generation (RAG) mekanizması için tasarlanmış sınıftır. Klinik kılavuzlar, tıp literatürü ve geçmiş vaka raporlarından bağlamsal bilgi çeker. `retrieve_context` metodu ile sorgu parametresiyle ilgili dokümanları getirir. `embed_query` metodu ile metin sorgularını vektör uzayına dönüştürür. Sentence-BERT veya Ada-002 embedding modeli kullanılabilir. FAISS veya Pinecone vektör veritabanı ile entegre çalışır. Klinik karar desteğini zenginleştirir ve hallüsinasyon riskini azaltır.

LLMReportGenerator: Büyük dil modeli (LLM) tabanlı klinik rapor üretici sınıfıdır. `generate_clinical_report` metodu ile tahminler, açıklamalar ve RAG context'i kullanarak yapılandırılmış klinik rapor üretir. GPT-4, Claude veya açık kaynak tıp modelleri (BioGPT, Med-PaLM) ile entegre edilebilir. Prompt engineering teknikleri ile doktor dilinde, kanıta dayalı raporlar oluşturur. RAGRetriever ile sıkı entegrasyon içerir, çünkü LLM'e context sağlanması gerekir. JSON formatında yapılandırılmış rapor ve Markdown formatında insan okunabilir rapor döndürür.

LLMReportGenerator ve RAGRetriever İlişkisi:

LLMReportGenerator sınıfı, RAGRetriever sınıfına bağımlıdır. Rapor üretimi sırasında önce RAGRetriever ile klinik kılavuzlardan ilgili bölümler çekilir. Ardından LLM'e tahminler, XAI açıklamaları ve çekilen context birlikte gönderilir. LLM, bu bilgileri sentezleyerek klinik rapor üretir. Bu yaklaşım, tamamen generatif raporlamaya göre daha güvenilir ve doğrulanabilir sonuçlar sağlar.

Belirsizlik Tahmini

UncertaintyEstimator: Model tahminlerindeki belirsizliği ölçen sınıfıdır. `mc_dropout_inference` metodu ile Monte Carlo Dropout tekniğini uygular. Aynı girdi için birden fazla tahmin yapılır ve dropout aktif tutulur. `compute_confidence_interval` metodu ile tahmin ortalaması ve güven aralığı hesaplanır. Epistemic ve aleatoric belirsizlik ayrımı yapılabilir. Bayesian deep learning prensipleri uygulanır. Klinisyene tahmin güvenilirliği hakkında istatistiksel bilgi sunar. Triaaj kararlarını iyileştirir, çünkü yüksek belirsizlik durumunda REVIEW seviyesi atanabilir.

Monte Carlo Dropout Süreci:

Model eğitim modunda tutulur ancak sadece dropout katmanları aktif bırakılır. Aynı EKG sinyali için N kez (örneğin 50 iterasyon) tahmin yapılır. Her iterasyonda farklı dropout mask uygulanır. N tahmin sonucundan ortalama ve standart sapma hesaplanır. Standart sapma yüksekse model tahmininde belirsizdir. Güven aralığı örneğin %95 seviyesinde hesaplanır: $\text{ortalama} \pm 1.96 \times \text{standart sapma}$.

Transformer Tabanlı Alternatif Mimari

TransformerBackbone: CNN tabanlı omurganın Transformer alternatifidir. Self-attention mekanizması ile EKG sinyallerini işler. forward metodu ile girdi sinyali alır ve gömme vektörü üretir. get_attention_weights metodu ile attention ağırlıklarını döndürür, böylece hangi zaman adımlarının önemli olduğu görülebilir. Positional encoding ile zamansal bilgi korunur. Multi-head attention ile farklı temsil alt uzayları öğrenilir. ECGBackbone ile aynı arayüzü implement eder, böylece değiştirilebilir (interchangeable). Uzun menzilli bağımlılıkları (long-range dependencies) CNN'den daha iyi yakalayabilir.

TransformerBackbone ve ECGBackbone İlişkisi:

Her iki sınıf da aynı arayüzü sağlar: girdi olarak 12×1000 sinyal alır, çıktı olarak 256 boyutlu gömme döndürür. ECGCNN sınıfı, başlatma sırasında backbone parametresi ile ECGBackbone veya TransformerBackbone alabilir. Strategy pattern uygulanır. Kullanıcı config dosyasında backbone_type parametresi ile seçim yapabilir. Bu esneklik, farklı mimari denemeleri kolaylaştırır ve A/B testleri yapılabilir.

Transformer Mimarisi Detayları:


Giriş sinyali patch'lere bölünür (örneğin 50 patch, her biri 20 örnek). Her patch embedding katmanından geçer ve vektöre dönüşür. Positional encoding eklenir. Multi-head self-attention katmanları (örneğin 8 head) uygulanır. Feed-forward network ve layer normalization katmanları ekle. Birden fazla Transformer bloğu (örneğin 6 blok) üst üste konur. Son çıktı global average pooling ile 256 boyutlu vektöre indirgenir.

Planlanan Sınıfların Sistemdeki Yeri

RAG Paketi (src.rag): Yeni bir paket oluşturulacak. RAGRetriever ve LLMReportGenerator bu pakette yer alacak. Backend Paketi ve Kontrat Paketi ile entegre edilecek. Yeni API endpoint: POST /generate-report eklenmesi planlanıyor.

Uncertainty Paketi (src.uncertainty): Yeni bir paket oluşturulacak. UncertaintyEstimator bu pakette yer alacak. Pipeline Paketi ile entegre edilecek. Tahmin response'larına uncertainty_metrics dictionary eklenecek.

Model Paketi Genişlemesi: TransformerBackbone, mevcut Model Paketi'ne eklenecek. ECGBackbone ile aynı seviyede alternatif omurga olarak konumlandırılacak. Backward compatibility korunacak, mevcut CNN modelleri çalışmaya devam edecek.



Şekil 17. Planlanan Sınıfların Diyagramı

Varlık-ilişki diyagramı

Bu bölümde CardioGuard-AI karar destek sisteminin veri modeli detaylı olarak açıklanmaktadır. Sistem, PTB-XL veritabanından gelen kaynak verileri, türetilmiş etiketleri, tahmin sonuçlarını ve konfigürasyon bilgilerini yönetmektedir.

Genel Bakış

CardioGuard-AI veri modeli, beş ana kategori altında organize edilmiş varlıklardan oluşmaktadır. Bu kategoriler, veri akışının farklı aşamalarını temsil eder ve sistemin veri yönetimi stratejisini yansıtır.

Kaynak Veri Varlıkları: PTB-XL veritabanından gelen ham verileri içerir. PATIENT varlığı hasta demografik bilgilerini (yaş, cinsiyet, boy, kilo) saklar. ECG_RECORD varlığı 12 derivasyonlu EKG kayıtlarının metadata bilgilerini içerir. SCP_STATEMENT varlığı standart EKG tanı kodlarını ve açıklamalarını barındırır. Bu varlıklar, sistemin temel veri kaynağını oluşturur ve değiştirilmez (immutable) niteliktedir.

Etiket Varlıkları: Model eğitimi için türetilmiş etiketleri içerir. SUPERCLASS_LABEL varlığı dört ana patoloji sınıfı için çoklu etiket yapısını saklar. MI_LOCALIZATION_LABEL varlığı MI tespit edilen kayıtlar için anatomik bölge etiketlerini içerir. Bu varlıklar, SCP kodlarından türetilir ve eğitim sürecinde kullanılır.

Tahmin Varlıkları: API üzerinden yapılan tahmin işlemlerini yönetir. PREDICTION_REQUEST varlığı tahmin isteklerinin meta bilgilerini (case_id, request_id, timestamp, kullanıcı bilgisi) saklar. PREDICTION_RESULT varlığı model tahminlerini ve olasılık skorlarını içerir. Bu varlıklar, sistemin operasyonel veri tabanını oluşturur.

Çıktı Varlıkları: Tahmin sonuçlarının detaylarını saklar. MI_LOCALIZATION_RESULT varlığı MI lokalizasyon tahminlerini içerir. XAI_ARTIFACT varlığı açıklanabilirlik görselleştirmelerinin dosya yollarını ve metadata bilgilerini barındırır.

Konfigürasyon Varlıkları: Sistem yapılandırma verilerini yönetir. MODEL_CHECKPOINT varlığı model versiyonlarını ve checkpoint dosya yollarını saklar. THRESHOLD_CONFIG varlığı eşik değerlerini ve triaj kurallarını içerir. Bu varlıklar, sistemin davranışını kontrol eder ve versiyon yönetimi sağlar.

VARLIK DETAYLARI

PATIENT: Hasta demografik bilgilerini saklar. Birincil anahtar patient_id (integer). Yaş, cinsiyet, boy ve kilo alanları içerir. Toplam 18,885 hasta kaydı bulunur. Yaş aralığı 18-89, ortalama 57.2 yıldır.

ECG_RECORD: EKG kayıtlarının metadata bilgilerini içerir. Birincil anahtar ecg_id (integer). PATIENT varlığına 1:N ilişki ile bağlanır. Dosya yolları (100Hz ve 500Hz), kayıt tarihi ve çapraz doğrulama katmanı (strat_fold) alanları vardır. Toplam 21,837 kayıt, her biri 10 saniye ve 12 derivasyon içerir.

SCP_STATEMENT: Standart EKG tanı kodlarını barındırır. Birincil anahtar scp_code (string). Tanı açıklaması ve diagnostik sınıf alanları içerir. ECG_RECORD ile M:N ilişki (SCP_CODE_ASSIGNMENT ara varlığı ile).

SUPERCLASS_LABEL: Dört patoloji sınıfı için çoklu etiket yapısı. Birincil anahtar ecg_id. ECG_RECORD ile 1:1 ilişki. label_MI, label_STTC, label_CD, label_HYP ve is_norm boolean alanları içerir. Etiket dağılımı: MI %25.1, STTC %24.0, CD %22.5, HYP %12.2, NORM %43.6.

MI_LOCALIZATION_LABEL: MI lokalizasyon etiketlerini saklar. Birincil anahtar ecg_id. ECG_RECORD ile 1:0..1 ilişki (opsiyonel). label_AMI, label_ASMI, label_ALMI, label_IMI, label_LMI boolean alanları vardır. Sadece MI pozitif kayıtlar için oluşturulur.

PREDICTION_REQUEST: API tahmin isteklerini yönetir. Birincil anahtar request_id (UUID). ECG_RECORD ve MODEL_CHECKPOINT varlıklarına yabancı anahtarlarla bağlanır. Timestamp, user_id, case_id ve input_file_path alanları içerir.

PREDICTION_RESULT: Model tahmin sonuçlarını saklar. Birincil anahtar result_id (UUID). PREDICTION_REQUEST ile 1:1 ilişki. prob_MI, prob_STTC, prob_CD, prob_HYP, prob_NORM olasılık alanları içerir. Triage_level (YÜKSEK/ORTA/DÜŞÜK/İNCELEME) ve agreement_type (model tutarlılık) alanları vardır.

MI_LOCALIZATION_RESULT: MI bölge tahminlerini içerir. Birincil anahtar localization_id (UUID). PREDICTION_RESULT ile 1:0..1 ilişki. prob_AMI, prob_ASMI, prob_ALMI, prob_IMI, prob_LMI alanları ve mapping_fingerprint (8ab274e06afa1be8) doğrulama alanı vardır.

XAI_ARTIFACT: Açıklanabilirlik çıktılarını saklar. Birincil anahtar artifact_id (UUID). PREDICTION_RESULT ile 1:N ilişki. artifact_type (GRADCAM, SHAP_WATERFALL, SHAP_SUMMARY), file_path ve sanity_check_passed alanları içerir.


MODEL_CHECKPOINT: Model versiyonlarını yönetir. Birincil anahtar checkpoint_id (integer). Model tipi (SUPERCLASS_CNN, BINARY_MI_CNN, LOCALIZATION_CNN, XGBOOST), version, checkpoint_hash ve is_active alanları vardır. Her model tipi için sadece bir checkpoint aktif olabilir.

THRESHOLD_CONFIG: Eşik değerleri ve triaj kurallarını içerir. mi_threshold, sttc_threshold, cd_threshold, hyp_threshold alanları karar eşiklerini belirler. ensemble_alpha (varsayılan 0.15) XGBoost ağırlığını saklar. triage_rules JSON alanı triaj belirleme kurallarını içerir.

Veri Bölümlemesi: PTB-XL 10 katlı çapraz doğrulama için bölümlenmiştir. Katmanlar 1-8 eğitim (17,469 kayıt), katman 9 doğrulama (2,189 kayıt), katman 10 test (2,179 kayıt) için kullanılır.

Planlanan Varlıklar (v2.0):

RAG_CONTEXT varlığı klinik kılavuz bağlamlarını saklayacak.
UNCERTAINTY_SCORE varlığı Monte Carlo belirsizlik değerlerini içerecek.
LLM_REPORT varlığı otomatik klinik raporları barındıracak.



Şekil 18. Varlık - İlişki Diyagramı

Dağıtım Diyagramı

Mimari beş ana katmandan oluşur. İstemci katmanı, web tarayıcı veya API istemcisi üzerinden HTTPS istekleri gönderir. Yük dengeleyici katmanı, NGINX ters proxy sunucusu ile port 443 üzerinden gelen trafiği dengeler ve SSL/TLS sonlandırma yapar. Uygulama sunucusu katmanı, iki Docker konteyneri içinde çalışan FastAPI servislerini barındırır. Her konteyner bağımsız olarak port 8000 ve 8001'de dinler. Depolama katmanı, model checkpoint'leri, log dosyaları ve XAI artifactları için merkezi dosya sistemi sağlar. Veri katmanı, PTB-XL veri setini salt okunur modda sunar.

Yatay ölçeklendirme stratejisi ile sistem yüksek erişilebilirlik sağlar. İki FastAPI konteyneri paralel çalışır ve NGINX round-robin algoritması ile istekleri dağıtır. Her konteyner PyTorch CNN modelleri, XGBoost ensemble katmanı ve XAI bileşenlerini içerir. Model dosyaları salt okunur volume olarak mount edilir ve tüm konteynerler aynı checkpoint'leri kullanır. Konteyner çökmesi durumunda NGINX otomatik olarak sağlıklı instance'a yönlendirme yapar. Healthcheck endpoint'i (/health) ile konteyner durumu sürekli izlenir.

Geliştirme ortamı yerel makinede Python 3.10 sanal ortam ile çalışır. Uvicorn reload mode sayesinde kod değişiklikleri anında yansır. Mini PTB-XL subset ile hızlı test yapılabilir. Docker Compose ile çok konteynerli yerel test ortamı oluşturulur. Pytest ile birim ve entegrasyon testleri çalıştırılır.

Sistemin v2.0 sürümü için altyapı genişletmeleri planlanmaktadır. Vektör veritabanı (FAISS veya Pinecone) RAG entegrasyonu için klinik kılavuzları depolayacaktır. LLM servisi (GPT-4 veya Claude API) otomatik rapor üretimi için eklenecektir. GPU kümesi (NVIDIA T4 veya A10) Transformer tabanlı modeller için sağlanacaktır. Anlık istek kapasitesi 100 req/s'den 1000 req/s'ye çıkarılacaktır. Konteyner sayısı 2'den 10+'ya ölçeklendirilecektir. Latency hedefi p99 metriğinde 500ms'den 200ms'ye düşürülecektir.

Bileşen Detayları

NGINX Yük Dengeleyici: Port 443'te HTTPS isteklerini dinler. SSL/TLS 1.3 sertifikası ile güvenli bağlantı sağlar. Port 80'den gelen HTTP istekleri HTTPS'e yönlendirilir. Upstream olarak iki FastAPI instance tanımlanır (10.0.2.10:8000 ve 10.0.2.11:8001). Health check ile her 30 saniyede backend durumu kontrol edilir. CORS middleware ile izin verilen domainler belirlenir. Rate limiting ile DDoS koruması uygulanır.

FastAPI Konteyner: Python 3.10 slim base image kullanılır. Uvicorn ASGI server ile 4 worker process çalıştırılır. Port 8000 ve 8001'de dinler. GET /health endpoint'i container healthcheck için kullanılır. GET /ready endpoint'i model yüklenme durumunu bildirir. PYTHONPATH environment variable ile uygulama yolu ayarlanır. Healthcheck her 30 saniyede bir curl ile /health'e istek atar, 3 başarısızlıkta container unhealthy işaretlenir.

Model Katmanı: Binary CNN modeli (ecgcnn.pt, 145KB) MI/Normal sınıflandırma yapar. Superclass CNN modeli (ecgcnn_superclass.pt, 433KB) dört patoloji sınıfını tespit eder. Lokalizasyon CNN modeli (ecgcnn_localization.pt, 433KB) beş anatomik bölge için tahmin üretir. Dört XGBoost modeli (MI, STTC, CD, HYP için birer model.json, her biri ~50KB) ensemble katmanını oluşturur. StandardScaler (scaler.joblib) feature normalizasyonu yapar. Kalibratörler (calibrator.joblib) olasılık kalibrasyonu sağlar. Tüm modeller container startup'ta belleğe yüklenir ve singleton pattern ile tutulur.


Depolama Yapısı: Ana dizin /opt/cardioguard-ai altında organize edilir. checkpoints dizini PyTorch ve XGBoost model dosyalarını saklar (salt okunur). logs/xgb_superclass dizini XGBoost eğitim loglarını ve metadata dosyalarını içerir (salt okunur). artifacts dizini XAI çıktılarını (PNG, JSON) saklar (okuma/yazma). data/ptb-xl dizini PTB-XL veri setini barındırır (salt okunur). outputs dizini raporlar ve sistem logları için kullanılır (okuma/yazma).

Docker Volume Mapping: Host ./checkpoints dizini container /app/checkpoints'e ro (read-only) modda mount edilir. Host ./logs/xgb_superclass dizini container /app/logs/xgb_superclass'a ro modda mount edilir. Host ./artifacts dizini container /app/artifacts'a rw (read-write) modda mount edilir. Bu yaklaşım ile model dosyaları container içinden değiştirilemez ve veri bütünlüğü korunur.

Ağ Yapılandırması: İstemci harici ağdan NGINX'e HTTPS ile erişir (443 portu). NGINX DMZ katmanında konumlanır (10.0.1.10 IP adresi). FastAPI instance'ları iç ağda çalışır (10.0.2.10 ve 10.0.2.11 IP adresleri). Sadece gerekli portlar açıktır, diğer tüm portlar firewall ile kapalıdır. TLS 1.3 ile transit şifreleme sağlanır.

Sunucu Gereksinimleri: Minimum donanım 4 çekirdek CPU, 8 GB RAM, 50 GB SSD gerektirir. Önerilen donanım 8 çekirdek CPU, 16 GB RAM, 100 GB NVMe SSD'dir. GPU gerekli değildir, tüm inference CPU üzerinde çalışır. Ağ bant genişliği minimum 100 Mbps, önerilen 1 Gbps'dir. Bu gereksinimler, eş zamanlı 100 istek/saniye yükünü karşılar.

Docker Compose Yapılandırması: cardioguard-api servisi Python 3.10-slim base image'dan build edilir. Resource limits olarak 4 CPU ve 8GB RAM tanımlanır. Resource reservations olarak 2 CPU ve 4GB RAM ayrılır. Healthcheck CMD ile curl -f http://localhost:8000/health komutu 30 saniyede bir çalıştırılır. Restart policy unless-stopped olarak ayarlanır, manuel durdurma dışında her zaman yeniden başlatılır.




Şekil 19. Dağıtım Diyagramı

SIRALI AKIŞ DİYAGRAMLARI

Sıralı akış diyagramları, sistemin çalışma zamanı davranışını zaman ekseninde gösterir. CardioGuard-AI'da dört ana akış ve gelecek sürüm için planlanan iki akış bulunmaktadır. Ana tahmin akışı, klinisyenin EKG göndermesinden AIResult yanıtının alınmasına kadar tüm adımları kapsar. Sistem başlatma akışı, fail-fast mekanizması ile model checkpoint'lerinin doğrulanması ve belleğe yüklenmesi sürecini gösterir. Tutarlılık kontrolü akışı, Binary ve Superclass MI modellerinin sonuçlarının karşılaştırılması ve triaj seviyesi belirlenmesini detaylandırır. XGBoost hibrit pipeline akışı, CNN backbone'dan feature extraction, StandardScaler normalizasyonu, XGBoost tahmin ve kalibrasyon adımlarını içerir.

Planlanan akışlar v2.0 sürümü için tasarlanmıştır. RAG entegrasyonu akışı, klinik kılavuzlardan bağlam çekme ve LLM ile rapor üretme sürecini gösterecektir. Belirsizlik tahmini akışı, Monte Carlo dropout ile 30 iterasyonluk tahmin üretme ve epistemic uncertainty hesaplama adımlarını içerecektir.


EKG sinyalinin yüklenmesinden sonuç üretilmesine kadar olan tam tahmin süreci yedi ana fazdan oluşur. Klinisyen POST /predict endpoint'ine EKG sinyalini gönderir. API katmanı MinMax normalizasyonu ile sinyali 0-1 aralığına ölçekler. Paralel tahmin fazında Superclass CNN ve Binary CNN modelleri eş zamanlı çalıştırılır. Superclass CNN dört patoloji sınıfı için olasılıklar üretir, Binary CNN MI/Normal kararı verir. XGBoost katmanı CNN backbone'dan 64 boyutlu feature vector çıkarır, StandardScaler ile normalize eder ve her sınıf için tahmin üretir. Ensemble fazında CNN ve XGBoost olasılıkları $\alpha=0.15$ ağırlığı ile birleştirilir. ConsistencyGuard bileşeni Binary ve Superclass MI olasılıklarını karşılaştırır ve AGREE_MI, AGREE_NO_MI veya DISAGREE durumunu belirler. MI tespit edilirse Lokalizasyon CNN beş anatomik bölge için tahmin üretir. GradCAM bileşeni Superclass CNN için zamansal açıklama haritaları oluşturur. AIResultMapper tüm sonuçları AIResult v1.0 kontratına göre JSON formatında paketler ve klinisyene döner.



Şekil 20. Ana Tahmin Akışı – Klinisyenden başlayarak API, CNN, XGBoost, Guard, Lokalizasyon ve XAI bileşenleri arasındaki etkileşim. 16 adımlık sıralı akış gösterilmektedir

Sistem Başlatma Akışı


Sistemin fail-fast prensibi ile güvenli başlatılması dört ana aşamadan oluşur. Main bileşeni startup'ta Doğrulayıcı modülünü çağırır. Doğrulayıcı her model checkpoint'i için boyut kontrolü yapar. Binary CNN için beklenen çıktı boyutu 1, Superclass CNN için 4, Lokalizasyon CNN için 5 olmalıdır. Boyut uyuşmazlığı durumunda CheckpointMismatchError hatası fırlatılır ve sistem sys.exit(1) ile durdurulur. Fingerprint kontrolünde MI lokalizasyon eşleme parmak izi 8ab274e06afa1be8 değeri ile karşılaştırılır. Değişiklik varsa MappingDriftError hatası fırlatılır. Tüm doğrulamalar başarılıysa Loader bileşeni çağırılır. Loader sırasıyla Binary CNN, Superclass CNN, Lokalizasyon CNN ve XGBoost modellerini belleğe yükler. Her model singleton pattern ile State bileşeninde saklanır. State bileşeni Main'e Hazır sinyali gönderir ve sistem API isteklerini kabul etmeye başlar.



Şekil 21. Sistem Başlatma Akışı – Main, Doğrulayıcı, Loader ve State bileşenleri arasındaki fail-fast mekanizması. Loop yapısı her model için tekrar eden kontrolleri gösterir.

Tutarlılık Kontrolü Akışı


Binary ve Superclass MI modellerinin sonuçları arasındaki uyum kontrolü üç senaryo üretir. API bileşeni ensemble sonrası P_{super} ve P_{binary} olasılıklarını ConsistencyGuard'a gönderir. Guard önce Superclass MI için karar eşiğini uygular: $P_{MI} \geq 0.01$ ise $super_karar$ pozitif olur. Sonra Binary MI için karar eşiğini uygular: $P_{MI} \geq 0.5$ ise $binary_karar$ pozitif olur. Her iki karar da pozitif ise $AGREE_MI$ sonucu ve YÜKSEK triaj seviyesi döner. Her iki karar da negatif ise $AGREE_NO_MI$ sonucu ve DÜŞÜK triaj seviyesi döner. Kararlar uyumsuz ise $DISAGREE$ sonucu ve İNCELEME triaj seviyesi döner. $DISAGREE_TYPE_1$ durumu Superclass pozitif ama Binary negatif olduğunda, $DISAGREE_TYPE_2$ durumu Binary pozitif ama Superclass negatif olduğunda oluşur.



Şekil 22. Tutarlılık Kontrolü Akışı – API ve Guard bileşenleri arasında alt (alternative) yapısı ile üç farklı senaryo gösterilmektedir.

XGBoost Hibrit Pipeline Akışı


CNN ve XGBoost modellerinin hibrit kombinasyonu dokuz adımlı bir pipeline oluşturur. API bileşeni EKG sinyalini CNN Backbone'a gönderir ve 64 boyutlu embedding vector alır. Bu vector, Superclass CNN'in son fully-connected katmanından önceki layer'dan çıkarılır. Scaler bileşeni StandardScaler ile feature'ları normalize eder, her boyutun ortalaması 0 ve standart sapması 1 olacak şekilde ölçekler. Loop yapısı ile her sınıf için (MI, STTC, CD, HYP) sırasıyla işlem yapılır. XGBoost modeli predict_proba metodu ile ham olasılık üretir. Calibrator bileşeni IsotonicRegression ile olasılığı kalibre eder ve güvenilirlik artırır. API dört sınıf için kalibre olasılıklar elde ettikten sonra ensemble fazına geçer. Ensemble formülü $P_{final} = 0.15 \times P_{cnn} + 0.85 \times P_{xgb}$ şeklindedir, yani XGBoost ağırlıklı kombinasyon yapılır.




Şekil 23 XGBoost Hibrit Pipeline Akışı – API, Backbone, Scaler, XGB ve Calib bileşenleri arasındaki etkileşim. Loop yapısı her sınıf için tekrar eden tahmin sürecini gösterir.

Planlanan Akışlar (v2.0)

Sistemin gelecek sürümünde iki yeni akış eklenecektir. RAG entegrasyonu akışında API bileşeni tahmin sonuçlarını ve klinik sorguyu RAG modülüne gönderecektir. RAG vektör veritabanından ilgili klinik kılavuz paragraflarını çekecek ve API'ye dönecektir. API tahmin sonuçları ile kılavuz bağlamını birleştirip LLM modülüne gönderecektir. LLM (GPT-4 veya Claude API) klinik rapor metni üretecek ve API'ye iletecektir. Belirsizlik tahmini akışında API bileşeni Model'e 30 iterasyon boyunca Dropout katmanları aktif şekilde istek gönderecektir. Her iterasyonda farklı nöronlar devre dışı kalacak ve farklı tahmin üretilen olacaktır. API 30 tahmin için ortalama ve varyans hesaplayacak, epistemic uncertainty değeri türetecektir. Yüksek belirsizlik durumunda otomatik olarak İNCELEME triajı atanacaktır.



Şekil 24 Planlanan Akışlar (v2.0) – RAG entegrasyonu ile klinik kılavuz kullanımı ve LLM rapor üretimi.



Şekil 25. Monte Carlo Dropout ile belirsizlik tahmini akışı.

5 TARTIŞMA

Bu çalışmanın “sonuç” çıktıları, bir sonraki dönemde geliştirilecek CardioGuard-AI projesinin yalnızca fikir düzeyinde kalmaması için; tanım–analiz–tasarım–planlama adımlarını uygulanabilir ve doğrulanabilir bir mühendislik dokümantasyonuna dönüştürmektedir. Bu kapsamda oluşturulan gereksinim listeleri, UML diyagramları (use case ve class), veri modeli (ERD), sistemin üretim perspektifi (deployment) ve çalışma zamanı akışını tanımlayan sıralı akış (sequence) kurgusu ile proje planı; hem geliştirme sürecini hızlandıran hem de hata/yeniden-iş yapma riskini azaltan verimli çıktılar olarak değerlendirilmiştir.

Öncelikle gereksinim setinin verimliliği, kapsamı netleştirmesi ve ölçülebilir hedefler sunması ile ortaya çıkmaktadır. Fonksiyonel gereksinimlerin yanı sıra güvenilirlik–güvenlik ve performans gereksinimlerinin ayrı başlıklar altında tanımlanması; “ne yapılacak?” sorusuna ek olarak “hangi kalite seviyesinde yapılacak?” sorusunu da cevaplamaktadır. Fail-fast yaklaşımı, API kontrat uyumu, eşleme parmak izi (fingerprint) gibi kontrollerin gereksinimlere bağlanması; entegrasyon sırasında ortaya çıkabilecek sessiz hataları erken aşamada engelleyerek hem zaman kaybını hem de yanlış klinik çıktıya gitme riskini düşürür. Benzer şekilde API yanıt süresi, model boyutu ve CPU desteği gibi performans hedefleri, sistemin yalnızca doğru çalışmasını değil; pratikte kullanılabilir olmasını da garanti altına alacak şekilde çerçevelemektedir.

Use case diyagramı, sistemin aktörlerini ve kritik etkileşimlerini netleştirerek verimlilik sağlar. Klinik senaryoda en önemli risklerden biri, belirsiz gereksinimler nedeniyle yanlış kullanıcı akışları tasarlamaktır. Use case çıktısı; klinisyen, sistem, model servisleri ve olası “inceleme/triage” adımlarını görünür hale getirerek, daha kod yazılmadan önce kapsam dışı işlerin elenmesini ve doğru işin doğru sırayla kurgulanmasını mümkün kılar. Bu, geliştirme boyunca geri dönüş (rework) maliyetini azaltır.

Class diyagramları ve paket bağımlılıkları ise modülerliği güvence altına alarak verimliliği artırır. CardioGuard-AI gibi bir sistemde veri hazırlama, model mimarileri, çıkarım pipeline'ı, XAI üretimi ve API kontratının birbirine karışması; hem test edilebilirliği düşürür hem de bakım maliyetini artırır. Modüllerin ayrıştırılmış biçimde tasarlanması; ekip içinde paralel geliştirmeyi kolaylaştırır, bir bileşende yapılan değişikliğin diğer bileşenlere etkisini sınırlayarak daha hızlı iterasyon sağlar. Ayrıca tutarlılık kapısı (Consistency Gate) gibi karar mekanizmalarının tasarım seviyesinde görünür olması, sistem davranışının “kodun içine gömülmek” yerine anlaşılabilir bir şekilde yönetilmesini sağlar.

ERD çıktısı, veri bütünlüğü ve izlenebilirlik açısından projenin verimli olmasının temel dayanaklarından biridir. Model çıktılarının (AIResult), kullanılan checkpoint versiyonlarının, eşik değerlerinin ve XAI artefact'larının ilişkilendirilerek saklanması; hem hataların kök neden analizini (root-cause analysis) kolaylaştırır hem de denetlenebilirliği artırır. Sağlık alanında “bu karar nasıl alındı?” sorusuna yalnızca model olasılığı ile değil; kullanılan model versiyonu, eşik konfigürasyonu ve açıklama artefact'ları ile cevap verebilmek kritik bir gereksinimdir. Bu nedenle ERD, ileride yapılacak klinik validasyon ve saha kullanım senaryolarında zaman kazandıran stratejik bir çıktıdır.

Dağıtım (deployment) perspektifi ve bileşen detayları, sistemin üretim ortamına taşınabilirliğini artırdığı için verimlidir. Örneğin NGINX ile TLS sonlandırma, birden fazla servis instance'ı ile yatay ölçeklenebilme ve healthcheck yaklaşımı; çalışır bir prototipin “tek makinede çalışan demo” olmaktan çıkıp operasyonel bir servise dönüşmesi için gerekli çerçeveyi sağlar. Bu yaklaşım, sistemin süreklilik ihtiyacını karşılar; servis arızalarında kontrollü geri dönüş ve izleme kabiliyeti ile kesintiyi azaltır. Sonuç olarak deployment tasarımı, projenin hayata geçme olasılığını artırdığı için doğrudan verimlilik göstergesidir.

Sequence diyagramları/akış kurgusu, çalışma zamanı davranışını adım adım görünür hale getirerek geliştirme sürecini hızlandırır. Ana tahmin akışında normalizasyon, paralel model çalıştırma (Superclass + Binary), hibrit karar katmanı (ör. XGBoost/ensemble), sonuç birleştirme ve tutarlılık kontrolü gibi adımların netleştirilmesi; implementasyon sırasında “hangi adım nerede yapılacak?” belirsizliğini azaltır ve test senaryolarının daha sistematik türetilmesini sağlar. Ayrıca planlanan v2.0 akışlarının (ör. belirsizlik tahmini, inceleme triajı, klinik kılavuz temelli raporlama/RAG yaklaşımı) tasarım seviyesinde konumlandırılması, sistemin genişleyebilirliğini ve sürdürülebilirliğini artıran bir verimlilik unsurudur.

İş paketleri tablosu, iş paketleri zamanlama tablosu ve UX şemaları, projenin yönetilebilirliğini ve uygulanabilirliğini yükseltir. İş paketleri; bağımlılıkları, teslimatları ve sorumlulukları netleştirerek “yapılacak işin” küçük ve ölçülebilir parçalara ayrılmasını sağlar. Zamanlama planı, hedeflenen sürede bitirme riskini düşürür ve kritik yolun erken tespit edilmesini kolaylaştırır. UX şemaları sayesinde kullanıcı arayüzü gereksinimleri geliştirme başlamadan netleşir; böylece sonradan yapılacak pahalı arayüz değişiklikleri azalır ve kullanıcı deneyimi erken aşamada doğrulanabilir hale gelir.

Bununla birlikte bu çıktılar, projenin mevcut aşamasının ağırlıklı olarak “dokümantasyon ve tasarım” odaklı olduğunu da göstermektedir. Henüz gerçek klinik ortam entegrasyonu, prospektif doğrulama, kullanıcı çalışmaları ve saha performansı gibi adımlar tamamlanmamıştır. Ayrıca veri seti dağılımı, sınıf dengesizliği, farklı cihazlardan gelen EKG’lerde olası domain shift, model kalibrasyonu ve açıklama yöntemlerinin klinik faydasının ölçülmesi gibi konular, uygulama aşamasında ek çalışma gerektirecektir. Buna rağmen, bu raporda üretilen sonuçlar; riskleri önceden görünür kıldığı, doğrulanabilir kalite hedefleri tanımladığı, sistem davranışını şeffaf biçimde modellediği ve projeyi uygulanabilir bir geliştirme planına bağladığı için verimlidir.

Tartışmanın Sonucu :

Sonuç olarak CardioGuard-AI için ortaya konan gereksinimler, tasarım artefaktları ve planlama çıktıları; bir sonraki dönemde yapılacak geliştirmeye doğrudan rehberlik edecek, yeniden-iş maliyetini azaltacak ve sistemin güvenilir, ölçeklenebilir ve denetlenebilir biçimde hayata geçirilmesini kolaylaştıracaktır. Bu nedenle Tartışma bölümünde savunulan temel görüş; elde edilen sonuçların projenin mühendislik kalitesini yükselten ve uygulamaya geçişi hızlandıran verimli çıktılar olduğudur.

6 İŞ PAKETLERİ VE ZAMANLAMA PLANI

Bu bölümde, raporun ana akışını bölmeden verilmesi uygun olmayan ancak çalışmayı destekleyen ek bilgiler yer alır. Kullanılan anketler, ayrıntılı tablolar, ek görseller, kod parçaları, teknik çizimler veya kullanıcı kılavuzu gibi materyaller bu kısımda sunulur. Her ek numaralandırılarak ve kısa bir açıklama ile düzenli şekilde verilir.

Bu bölümde CardioGuard-AI projesinin bir sonraki dönemde gerçekleştirilecek geliştirme süreci, iş paketleri (WBS) yaklaşımıyla yapılandırılarak sunulmaktadır. Amaç; mevcut tezde oluşturulan gereksinim, UML ve veri modeli çıktıları üzerine kurulu biçimde, implementasyonun yönetilebilir teslimatlar halinde ilerlemesini sağlamaktır. Bu kapsamda tamamlanan çalışmalar “Faz 1”, planlanan çalışmalar ise “Faz 2–Faz 4” altında organize edilmiştir.

Faz Yapısı ve Kapsam

Proje planı dört fazdan oluşmaktadır:

Faz 1 (Tamamlandı): Temel AI pipeline ve Python backend

Faz 2 (Planlı): Java orkestratör ve entegrasyon

Faz 3 (Planlı): Frontend ve klinik kullanıma hazırlık

Faz 4 (Planlı): Deployment ve operasyonel süreçler (izleme, CI/CD, güvenlik)

Bu fazlar; modelleme/çıkartım bileşenlerinden başlayarak servisleşme, kullanıcı arayüzü ve üretim ortamına geçişe kadar uzanan uçtan uca geliştirme hattını temsil eder.

Faz 1: Temel AI Pipeline ve Python Backend (Tamamlandı)

Faz 1 kapsamında; veri hazırlama, CNN tabanlı model altyapısı, model eğitimi, hibrit/ensemble yaklaşımı, tutarlılık kontrolü (Consistency Gate), XAI bileşenleri (Grad-CAM/SHAP) ve Python servis katmanı tamamlanmıştır. Faz 1’de tamamlanan iş paketleri ve her bir paketin çıktısı Tablo 1’de sunulmaktadır.

Bu fazın sonunda sistemin modüler yapısı netleşmiş; model, veri, pipeline, XAI, kontrat ve backend bileşenleri ayrı sorumluluk alanları olarak konumlandırılmıştır. Bu yapı, tezde tanımlanan paket mimarisi ile uyumludur (src.models, src.data, src.pipeline, src.xai, src.contracts, src.backend).

Tablo 10 Faz 1 Tamamlanan İş Paketleri ve Çıktıları (WP1.0–WP1.7)

WP ID	İş Paketi Adı	Durum	Çıktılar	Tamamlanma
WP1.0	Proje Altyapısı	☑	Repo yapısı, config, CI/CD	%100
WP1.1	Veri Hazırlama	☑	PTB-XL loader, etiketleme, cache sistemi	%100
WP1.2	CNN Model Altyapısı	☑	ECGBackbone, BinaryHead, MultiClassHead, FiveClassHead	%100
WP1.3	Model Eğitimi	☑	Binary MI, Superclass, Lokalizasyon modelleri	%100
WP1.4	Hibrit Ensemble	☑	XGBoost OvR, embedding pipeline	%100
WP1.5	Tutarlılık Kapısı	☑	ConsistencyGuard, AgreementType, triage	%100
WP1.6	XAI Modülü	☑	Grad-CAM, SHAP, SanityChecker, Reporter	%100
WP1.7	Python API	☑	FastAPI, AIResult v1.0 kontratı	%100

Faz 2: Java Orkestratör ve Entegrasyon (Planlı)

Faz 2'nin amacı, Python AI servisinin kurumsal kullanım senaryolarına uygun şekilde Java/Spring Boot tabanlı bir orkestrasyon katmanı tarafından yönetilmesidir. Bu fazda; gateway mimarisi, veritabanı entegrasyonu, kimlik doğrulama/rol yönetimi, RAG tabanlı klinik bilgi erişimi ve workflow yönetimi gibi bileşenler ele alınacaktır. Faz 2 iş paketleri, beklenen teslimatlar ve tamamlanma ölçütleri Tablo 11'de sunulmuştur.

Faz 2 planı, entegrasyon riskini azaltmak için altyapı kurulumundan başlayıp, veri/servis katmanları ve güvenlik kontrolleri üzerinden ilerleyecek şekilde kurgulanmıştır.

Tablo 11 Faz 2 İş Paketleri ve Çıktıları (WP2.1–WP2.7)

WP ID	İş Paketi Adı	Amaç	Alt İşler	Çıktılar	Kabul Kriteri	Bağımlılık	Süre
WP 2.1	Java Spring Boot Altyapısı	Orkestrasyon katmanını oluşturmak	Spring Boot setup, Maven/Gradle, JPA entity'ler	Çalışan Spring Boot projesi	Build başarılı, health endpoint çalışır	WP1.7	1 hafta
WP 2.2	AI Gateway Servisi	Python AI servisine köprü	RestTemplate/WebClient, retry logic, circuit breaker	Gateway controller + service	Python API ile iletişim kuruldu	WP2.1	1 hafta
WP 2.3	Veritabanı Katmanı	Analiz geçmişi ve kullanıcı yönetimi	PostgreSQL schema, JPA repository'ler, migration	DB schema + CRUD operasyonları	Veri kalıcı, tekrar okunabilir	WP2.1	1 hafta
WP 2.4	Kimlik Doğrulama	JWT tabanlı auth sistemi	Spring Security, JWT token, rol yönetimi	Auth endpoint'leri + token üretimi	Login/logout çalışır	WP2.3	1 hafta
WP 2.5	RAG Entegrasyonu	Klinik bilgi bankası sorgusu	LangChain4j, ChromaDB, embedding modeli	RAG pipeline çalışır	Sorgu-cevap akışı tamamlandı	WP2.2	2 hafta
WP 2.6	İş Akışı Motoru	Çok adımlı analiz orkestrasyonu	State machine, async işlem, event'ler	Workflow engine çalışır	Analiz adımları sıralı çalışır	WP2.2, WP2.5	1 hafta
WP 2.7	API Gateway & Dokümantasyon	Dış dünyaya açık API	OpenAPI spec, Swagger UI, rate limiting	API dokümantasyonu	Swagger'dan test edilebilir	WP2.6	1 hafta

Faz 3: Frontend ve Klinik Kullanıma Hazırlık (Planlı)


Faz 3 kapsamında hedef; klinisyen kullanımını destekleyecek web arayüzünün geliştirilmesi, EKG yükleme ve sonuç ekranlarının oluşturulması, XAI çıktılarının arayüzde görselleştirilmesi ve raporlama/geçmiş ekranları ile izlenebilirliğin artırılmasıdır. Faz 3 iş paketleri ve hedef çıktıları Tablo 12’te sunulmuştur.

Bu faz, ders çıktısı olarak istenen en az 3 sayfanın şematik UX tasarımı ile de doğrudan ilişkilidir. Bu nedenle Faz 3 kapsamında üretilen arayüz taslakları, tezde Şekil 26 ,Şekil 27 ve Şekil 28 olacak şekilde sunulmuştur.


Şekil 26. UX Şema 1 (EKG Yükleme)

Tablo 12 Faz 3 İş Paketleri ve Çıktıları (WP3.1–WP3.8)

WP ID	İş Paketi Adı	Amaç	Alt İşler	Çıktılar	Kabul Kriteri	Bağımlılık	Süre
WP 3.1	Frontend Altyapısı	Modern web arayüzü temeli	React/Next.js setup, design system, routing	Boş proje + temel yapı	Build başarılı	WP2.7	1 hafta
WP 3.2	EKG Yükleme Ekranı	Kullanıcı dosya upload akışı	Drag-drop, format validasyon, preview	Upload sayfası çalışır	Dosya başarıyla yüklenebilir	WP3.1	1 hafta
WP 3.3	Analiz Sonuç Ekranı	Tahmin sonuçlarının gösterimi	Olasılık chart'ları, triage badge, özet	Sonuç dashboard'u	Tüm tahmin verileri görünür	WP3.1	1 hafta
WP 3.4	XAI Görselleştirme	Açıklama artefact'larının gösterimi	12-lead overlay, SHAP grafikler, narrative	XAI viewer komponenti	Grad-CAM ve SHAP görünür	WP3.3	1 hafta
WP 3.5	Geçmiş & Raporlar	Analiz geçmişi ve PDF export	Tablo listeleme, filtreleme, PDF üretimi	Geçmiş sayfası + export	PDF indirilebilir	WP3.3	1 hafta
WP 3.6	Kullanıcı Yönetimi	Login, profil, ayarlar	Auth akışı, profil düzenleme	Kullanıcı sayfaları	Giriş/çıkış çalışır	WP3.1, WP2.4	1 hafta
WP 3.7	Responsivite & A11y	Mobil uyum ve erişilebilirlik	Mobile-first CSS, ARIA labels, contrast	Test raporu	WCAG 2.1 AA uyumlu	WP3.2-3.6	1 hafta
WP 3.8	E2E Test & QA	Uçtan uca test otomasyonu	Playwright/Cypress, test senaryoları	Test suite + raporlar	%80 coverage	WP3.7	1 hafta



Şekil 27. UX Şema 2 (Sonuçlar)



Şekil 28. UX Şema 3 (XAI Görüntüleme/Raporlama)

Faz 4: Deployment ve Operasyon (Planlı)

Faz 4; sistemin üretim ortamına taşınması ve operasyonel olgunluğunun artırılması için planlanan çalışmaları kapsar. Bu fazda konteynerizasyon (Docker), ölçeklenebilir dağıtım (Kubernetes), izleme (monitoring), CI/CD süreçleri ve güvenlik denetimi tamamlanacaktır. Faz 4 iş paketleri Tablo 13'te sunulmuştur.

Tablo 13 Faz 4 Deployment ve Operasyon

WP ID	İş Paketi Adı	Amaç	Alt İşler	Çıktılar	Kabul Kriteri	Bağımlılık	Süre
WP 4.1	Docker Compose	Tüm servislerin konteynerizasyonu	Python, Java, DB, Redis container'ları	docker-compose .yaml	Tek komutla ayağa kalkar	Faz 2-3	1 hafta
WP 4.2	Kubernetes Manifests	Ölçeklenebilir deployment	Deployment, Service, Ingress YAML'ları	K8s manifest'leri	K8s cluster'da çalışır	WP4.1	1 hafta
WP 4.3	Monitoring Stack	Sistem izleme altyapısı	Prometheus, Grafana, alerting	Dashboard + alert kuralları	Metrikler görünür	WP4.2	1 hafta
WP 4.4	CI/CD Pipeline	Otomatik build ve deploy	GitHub Actions, staging/prod ortamları	Pipeline YAML'ları	Push'ta otomatik deploy	WP4.2	1 hafta
WP 4.5	Güvenlik Audit	Penetrasyon testi ve güvenlik	OWASP kontrolleri, bağımlılık taraması	Güvenlik raporu	Kritik açık yok	WP4.4	1 hafta

Zamanlama Planı (24 Haftalık)


Proje için önerilen zamanlama planı toplam 24 hafta olarak yapılandırılmıştır. Plan; Faz 1'in 1–8. haftalarda tamamlandığını, Faz 2'nin 9–15. haftalarda, Faz 3'ün 16–21. haftalarda, Faz 4'ün ise 22–24. haftalarda yürütüleceğini göstermektedir. Haftalık aktif iş paketleri ve kilometre taşları Tablo 14'te sunulmuştur.

Tablo 14 Planlama

Hafta	Faz	Aktif İş Paketleri	Kilometre Taşı
1-8	Faz 1	WP1.1 → WP1.7	☒ M1: AI Pipeline tamamlandı
9	Faz 2	WP2.1	M2: Spring Boot altyapısı hazır
10	Faz 2	WP2.2, WP2.3	M3: AI Gateway + DB katmanı
11	Faz 2	WP2.4	M4: Kimlik doğrulama çalışır
12-13	Faz 2	WP2.5	M5: RAG entegrasyonu tamamlandı
14	Faz 2	WP2.6	M6: Workflow engine çalışır
15	Faz 2	WP2.7	M7: Java API dokümanate edildi
16	Faz 3	WP3.1	M8: Frontend altyapısı hazır
17	Faz 3	WP3.2, WP3.3	M9: Upload + Sonuç ekranları
18	Faz 3	WP3.4, WP3.5	M10: XAI viewer + Geçmiş
19	Faz 3	WP3.6	M11: Kullanıcı yönetimi
20	Faz 3	WP3.7	M12: Responsive + A11y
21	Faz 3	WP3.8	M13: E2E testler pass
22	Faz 4	WP4.1, WP4.2	M14: Konteyner altyapısı
23	Faz 4	WP4.3, WP4.4	M15: Monitoring + CI/CD
24	Faz 4	WP4.5	M16: Güvenlik audit tamamlandı

Gantt Şeması

Zaman çizelgesinin görsel takibi için Gantt şeması hazırlanmıştır. Bu şema; fazların ardışıklığını, her iş paketinin sürelerini ve proje akışını görsel olarak özetlemektedir. Gantt şeması Şekil 24'te sunulmuştur.



Şekil 29 Gantt Şeması

Gantt Tablosu (Haftalık İş Paketi Dağılımı)

Gantt şemasına ek olarak, hızlı okunabilirlik sağlamak amacıyla iş paketlerinin haftalara göre dağılımını gösteren görsel bir tablo hazırlanmıştır. Bu tablo, hangi iş paketinin hangi haftada aktif olduğunu tek bakışta göstermektedir. Haftalık dağılım tablosu Tablo 15 olarak sunulmuştur.

Tablo 15 Gantt Tablosu

İş Paketi	1-8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24
Faz 1	■	.	.	.	.	.	.	.	.	.	.	.	.	.	.	.	.
WP2.1	.	■	.	.	.	.	.	.	.	.	.	.	.	.	.	.	.
WP2.2	.	.	■	.	.	.	.	.	.	.	.	.	.	.	.	.	.
WP2.3	.	.	■	.	.	.	.	.	.	.	.	.	.	.	.	.	.
WP2.4	.	.	.	■	.	.	.	.	.	.	.	.	.	.	.	.	.
WP2.5	.	.	.	.	■	■	.	.	.	.	.	.	.	.	.	.	.
WP2.6	.	.	.	.	.	.	■	.	.	.	.	.	.	.	.	.	.
WP2.7	.	.	.	.	.	.	.	■	.	.	.	.	.	.	.	.	.
WP3.1	.	.	.	.	.	.	.	.	■	.	.	.	.	.	.	.	.
WP3.2	.	.	.	.	.	.	.	.	.	■	.	.	.	.	.	.	.
WP3.3	.	.	.	.	.	.	.	.	.	■	.	.	.	.	.	.	.
WP3.4	.	.	.	.	.	.	.	.	.	.	■	.	.	.	.	.	.
WP3.5	.	.	.	.	.	.	.	.	.	.	■	.	.	.	.	.	.
WP3.6	.	.	.	.	.	.	.	.	.	.	.	■	.	.	.	.	.
WP3.7	.	.	.	.	.	.	.	.	.	.	.	.	■	.	.	.	.
WP3.8	.	.	.	.	.	.	.	.	.	.	.	.	.	■	.	.	.
WP4.1	.	.	.	.	.	.	.	.	.	.	.	.	.	.	■	.	.
WP4.2	.	.	.	.	.	.	.	.	.	.	.	.	.	.	.	■	.
WP4.3	.	.	.	.	.	.	.	.	.	.	.	.	.	.	.	■	.
WP4.4	.	.	.	.	.	.	.	.	.	.	.	.	.	.	.	■	.
WP4.5	.	.	.	.	.	.	.	.	.	.	.	.	.	.	.	.	■

Açıklama: ■ = Tamamlandı | ■ = Planlı aktif çalışma | . = Pasif

Bölüm Özeti

Bu bölümde sunulan iş paketleri ve 24 haftalık zamanlama planı; CardioGuard-AI projesinin bir sonraki dönemde uygulanabilir biçimde geliştirilmesi için net teslimatlar, takvimlenmiş hedefler ve faz bazlı yürütme çerçevesi ortaya koymaktadır. Böylece tezde üretilen tasarım çıktıları, doğrudan implementasyona aktarılabilir bir proje planına dönüştürülmüştür.

7 KAYNAKLAR

Bu bölümde, proje hazırlanırken yararlanılan tüm kitap, makale, tez, web sitesi ve diğer kaynaklar liste halinde verilir. Kaynaklar belirli bir yazım kuralına (ör. IEEE, APA vb.) uygun biçimde düzenlenir ve metin içinde kullanılan atıflarla uyumlu olmalıdır. Böylece çalışmanın dayandığı bilgiler açıkça gösterilir ve akademik güvenilirlik sağlanır.

- [1] H. Wang *et al.*, “Artificial intelligence–based accurate myocardial infarction mapping using 12-lead electrocardiography,” *European Heart Journal - Digital Health*, vol. 6, no. 5, pp. 939–948, Sep. 2025, doi: 10.1093/EHJDH/ZTAF077.
- [2] Z. Shi, Y. Hu, G. Mo, and J. Wu, “Attention-based CNN-LSTM and XGBoost hybrid model for stock prediction,” Apr. 2022, Accessed: Jan. 22, 2026. [Online]. Available: <https://arxiv.org/pdf/2204.02623>
- [3] P. Wagner *et al.*, “PTB-XL, a large publicly available electrocardiography dataset,” *Scientific Data* 2020 7:1, vol. 7, no. 1, pp. 154–, May 2020, doi: 10.1038/s41597-020-0495-6.

- [4] N. Strodthoff, P. Wagner, T. Schaeffter, and W. Samek, “Deep Learning for ECG Analysis: Benchmarks and Insights from PTB-XL,” *IEEE J. Biomed. Health Inform.*, vol. 25, no. 5, pp. 1519–1528, May 2021, doi: 10.1109/JBHI.2020.3022989.
- [5] A. E. M. Atwa, E. S. Atlam, A. Ahmed, M. A. Atwa, E. M. Abdelrahim, and A. I. Siam, “Interpretable Deep Learning Models for Arrhythmia Classification Based on ECG Signals Using PTB-X Dataset,” *Diagnostics* 2025, Vol. 15, vol. 15, no. 15, Aug. 2025, doi: 10.3390/DIAGNOSTICS15151950.
- [6] N. Jourdan, S. Sen SINTEF, E. Johannes Husom SINTEF, E. Garcia-Ceja SINTEF, T. Biegel, and J. Metternich, “On The Reliability Of Machine Learning Applications In Manufacturing Environments,” Dec. 2021, Accessed: Jan. 22, 2026. [Online]. Available: <https://arxiv.org/pdf/2112.06986>
- [7] M. Elhaddad and S. Hamam, “AI-Driven Clinical Decision Support Systems: An Ongoing Pursuit of Potential,” *Cureus*, vol. 16, no. 4, p. e57728, Apr. 2024, doi: 10.7759/CUREUS.57728.
- [8] N. A. Ali Abdu and K. O. Basulaim, “Machine learning in concept drift detection using statistical measures,” *International Journal of Computers and Applications*, vol. 46, no. 5, pp. 281–291, May 2024, doi: 10.1080/1206212X.2023.2289706;WEBSITE:WEBSITE:TFOPB;PAGEGROUP:STRING:PUBLICATION.

8 ÖZGEÇMİŞ

Bu bölümde, yazarın kısa akademik ve kişisel bilgileri yer alır. Eğitim geçmişi, varsa staj/iş deneyimleri, ilgi alanları ve projeyle ilgili yetkinlikler özetlenir. Amaç, çalışmayı hazırlayan kişinin temel profilini kısa ve anlaşılır şekilde tanıtmaktır.